

Morphe

Plataforma de Processamento Digital de Sinais em FPGA
Manual do sistema: funcionamento e estrutura

Antonio Nicassio Santos Lima

Estágio no LabPS/UEFS — supervisão: Prof. Armando S. Sanca

24 de setembro de 2026

Resumo

O Morphe é uma plataforma de ensino de Processamento Digital de Sinais. O aluno prepara um sinal num aplicativo no computador, escolhe uma operação, e a operação é executada em ponto fixo na FPGA de uma placa DE1-SoC; o aplicativo mostra lado a lado o resultado do hardware e a referência calculada em ponto flutuante, e a diferença entre os dois é o objeto de estudo.

São cinco as operações em hardware — convolução, filtros FIR e IIR, FFT e IFFT, sobre blocos de 1024 amostras — e sinais de qualquer tamanho são processados por blocos, com técnicas que dão o mesmo resultado de uma operação única. O conversor analógico-digital da placa captura sinais reais, à taxa de amostragem que o aluno escolher, até 200 kHz. A FFT chega a cerca de 92 dB de relação sinal-ruído contra a referência; o IIR coincide bit a bit com o seu modelo; e duas placas atenderam seis clientes simultâneos sem perder nem trocar uma resposta.

Este manual descreve como o sistema funciona e como ele está organizado, para o professor e o monitor que o operam e para quem vai estendê-lo. A plataforma nasceu como Trabalho de Conclusão de Curso de Carlos Valadão na UEFS e foi continuada num estágio curricular no LabPS/UEFS em 2026, que a tornou reproduzível a partir do repositório, utilizável por uma turma e documentada; o capítulo 1 diz o que veio de cada um.

Sumário

1	Introdução	6
1.1	O que é o Morphe	6
1.2	Para que serve no ensino de PDS	6
1.3	Histórico	7
1.4	Visão geral	7
1.5	Como ler este manual	8
2	Arquitetura em três camadas	9
2.1	As camadas e o que cabe a cada uma	9
2.2	O caminho de uma operação	10
2.3	Onde está cada camada no repositório	12
3	O hardware	13
3.1	A placa DE1-SoC	13
3.2	Pontes e mapa de memória	14
3.3	Os aceleradores	15
3.3.1	O protocolo comum	16
3.3.2	Convolução e FIR: o <code>conv1d</code>	16
3.3.3	FFT e IFFT: o núcleo da Intel	17
3.3.4	IIR: a cascata de seções de segunda ordem	17
3.4	A aquisição: o ADC da placa	18
3.4.1	O conversor e o conector	19
3.4.2	Por que um controlador próprio	19
3.4.3	Captura única e captura contínua	20
3.4.4	O que foi validado	20
4	O servidor na placa	21
4.1	Estrutura	21
4.2	Esperar a FPGA	22
4.3	A marca de FPGA preparada	22
4.4	Outros cuidados	23
4.5	Compilação e início automático	23
4.6	Códigos de status	24
5	O protocolo Morphe-TCP	25
5.1	Uma conexão por operação	25
5.2	Os cabeçalhos	25
5.3	As operações	26
5.4	A descoberta: <code>PING</code>	27
5.5	A captura contínua do ADC	27
5.6	Como acrescentar uma operação	28

6	Representação numérica	29
6.1	Os dois formatos	29
6.2	A regra dos 6 dB por bit	30
6.3	A normalização da entrada	30
6.4	O que o núcleo da FFT faz por dentro	31
6.5	Convolução, FIR e IIR	31
6.6	O ADC	32
6.7	Números para referência rápida	32
6.8	Regras práticas	32
7	O aplicativo cliente	33
7.1	Abrir o aplicativo	33
7.2	As janelas	33
7.3	A janela de aquisição	35
7.4	Os módulos	35
7.5	O pacote <code>.mrph</code> e o comparador	35
7.6	Sinais maiores que o hardware: processamento em blocos	36
7.6.1	Convolução e FIR: <i>overlap-add</i>	36
7.6.2	FFT e IFFT: o algoritmo de quatro passos	36
7.6.3	IIR: blocos com aquecimento	38
7.6.4	O custo	38
8	Várias placas, vários alunos	39
8.1	Descoberta	39
8.2	Escolha: a placa que responder mais rápido	39
8.3	A fila e o tempo de resposta	40
8.4	O que foi medido	40
8.5	O que não existe	41
8.6	Sintoma, causa e o que fazer	41
9	Preparação e operação do laboratório	42
9.1	A rotina	42
9.2	O que o <code>morphe-up.sh</code> faz	42
9.3	O <code>tether</code> da licença	44
9.4	A instalação de turma	44
9.5	As chaves SSH	45
9.6	O servidor no boot da placa	45
9.7	O Quartus em todos os computadores	45
9.8	O aplicativo nos outros computadores	46
9.9	A placa na rede certa	46
9.10	Uma placa nova	47
9.11	Sintoma, causa e o que fazer	47
10	Desenvolvimento e verificação	48
10.1	Três regras antes de começar	48
10.2	Recompilar o bitstream	48
10.3	Testbenches	49
10.4	Testes contra a placa	50
10.5	Sem placa: o servidor em simulação	50
10.6	A proveniência	51
10.7	Fluxo de trabalho com o <code>git</code>	51
10.8	Acrescentar um acelerador	51

11 Limitações e trabalho futuro	52
11.1 Hardware	52
11.2 Aquisição	52
11.3 Infraestrutura	53
11.4 Ideias que a plataforma já permite	53
A Estrutura do repositório	54
B Referência rápida	56

Lista de Figuras

1.1	Visão geral: os computadores do laboratório falam com as placas pela rede (TCP, porta 5000); a estação programa a FPGA pelo USB-Blaster e sobe o servidor por SSH.	8
2.1	As três camadas e os módulos de cada uma.	9
2.2	O caminho de uma operação, do clique na janela ao gráfico.	11
3.1	Mapa de memória visto pelo servidor: memórias de dados atrás da ponte HPS→FPGA e registradores de controle atrás da ponte leve. Os endereços são deslocamentos a partir da base de cada ponte.	14
3.2	O que há dentro da FPGA: quatro aceleradores e o controlador do ADC, cada um com as suas memórias e os seus registradores de controle.	15
3.3	O bloco IIR: cascata de seções de segunda ordem (acima) e a seção em forma direta I (abaixo). Um só multiplicador-acumulador atende todas as seções, dois ciclos por seção.	18
3.4	O caminho da aquisição: o controlador próprio dispara cada conversão do LTC2308 a $1/f_s$ e grava a amostra na memória de captura, que o servidor lê pela ponte.	19
5.1	Os cabeçalhos de requisição e de resposta, em bytes.	25
6.1	Os dois formatos de ponto fixo, bit a bit.	29
7.1	<i>Overlap-add</i> : cada bloco de L amostras é convoluído na placa; as caudas de $M - 1$ amostras se somam.	37
7.2	FFT de $N = M \cdot 1024$ pontos pelo algoritmo de quatro passos: M FFTs de 1024 na placa, fatores de giro e DFTs de M pontos no PC.	37
7.3	IIR por blocos: cada bloco começa algumas amostras antes (<i>aquecimento</i>) e essa parte da saída é descartada.	38
8.1	Escolha da placa: o cliente sonda todas em paralelo e fica com a que responder primeiro. Uma placa ocupada só responde ao fim da operação em curso.	40
9.1	O que o <code>morphe-up.sh</code> faz, em ordem.	43

Lista de Tabelas

1.1	O que o estágio acrescentou ao projeto original.	7
2.1	Responsabilidades de cada camada.	9
3.1	Recursos da FPGA ocupados pelo projeto (compilação de 24/09/2026).	13
3.2	Os registradores do controlador do ADC, na ponte leve, e a sua memória.	20
4.1	Códigos de status das respostas	24
5.1	As operações do protocolo e o que vai em cada <i>payload</i> . Todos os valores ocupam 4 bytes.	26
6.1	Os formatos de ponto fixo e onde cada um é usado.	29
6.2	FFT de um sinal de pico 3,3 com escalas crescentes, comparada com <code>np.fft.fft</code> (placa, 10/09/2026).	30
6.3	Efeito da normalização, medido na placa (10/09/2026).	30
6.4	Erros medidos na placa, para comparação.	32
7.1	Os módulos do cliente, em <code>Python/</code>	36
8.1	Vários clientes simultâneos, operações de 1024 amostras, metade convoluções (≈ 215 ms) e metade FFTs (≈ 21 ms). Placa livre: mediana de 120 ms (22/09/2026).	40
8.2	Sintomas ligados a várias placas e vários clientes.	41
9.1	As opções do <code>morphe-up.sh</code>	43
9.2	Sintomas da operação do laboratório.	47
10.1	Os testes contra a placa.	50
A.1	A documentação técnica, em <code>docs/</code> e na raiz.	55

Capítulo 1

Introdução

1.1 O que é o Morphe

O Morphe é uma plataforma para executar operações de Processamento Digital de Sinais (PDS) em hardware e comparar o resultado com o que o computador calcula. O aluno prepara um sinal numa janela do aplicativo, escolhe a operação e recebe de volta duas respostas lado a lado: a que a FPGA de uma placa DE1-SoC calculou em ponto fixo e a que o próprio computador calculou em ponto flutuante. A diferença entre as duas é o objeto de estudo.

São cinco as operações executadas em hardware:

Convolução linear de dois sinais de até 1024 amostras cada, com saída de até 2047 amostras.

Filtro FIR a mesma convolução, com a resposta ao impulso vinda de um projetista de filtros por especificação.

Filtro IIR cascata de até 16 seções de segunda ordem (ordem até 32), também com projetista próprio.

FFT transformada de Fourier discreta de 1024 pontos.

IFFT a transformada inversa, no mesmo núcleo da FFT.

Além delas, a plataforma **acquire sinais**: o conversor analógico-digital da placa captura um sinal real, de um gerador de funções ou de um sensor, à taxa de amostragem que o aluno escolher, de 1 a 200 kHz, constante durante toda a captura, e a captura pode ser usada como entrada de qualquer uma das cinco operações (seção 3.4).

O hardware trabalha com blocos de tamanho fixo (1024 amostras), mas o aplicativo aceita sinais de qualquer tamanho: divide o sinal em blocos, manda cada um à placa e recompõe o resultado, com técnicas que dão a mesma resposta que uma operação única daria (capítulo 7).

1.2 Para que serve no ensino de PDS

Nas disciplinas de PDS as operações são estudadas com números reais, e o computador as calcula em ponto flutuante de 64 bits, que para quase todo fim didático é o mesmo que calcular com números reais. Um circuito digital dedicado não trabalha assim: usa ponto fixo, com um número pequeno de bits para a parte fracionária, e cada multiplicação precisa ser arredondada ou truncada.

O Morphe torna essa diferença visível e mensurável. Com ele o aluno pode:

- ver o erro de quantização de uma FFT em decibéis e observar que ele melhora 6 dB a cada bit de faixa aproveitada (capítulo 6);

- provocar uma saturação ou um estouro de acumulador e reconhecer o sintoma na saída;
- comparar um filtro IIR projetado em ponto flutuante com o mesmo filtro executado em ponto fixo, e entender por que o hardware usa seções de segunda ordem e não um polinômio de ordem alta;
- medir quanto tempo cada operação leva na placa e relacionar esse tempo com o número de operações do algoritmo;
- capturar um sinal de verdade pelo conversor da placa, ver o *aliasing* de um tom acima de $f_s/2$ e medir quantos bits efetivos o conversor entrega.

1.3 Histórico

O Morphe nasceu como Trabalho de Conclusão de Curso de Carlos Valadão na UEFS, *Implementação de Ferramentas de Computação Numérica para o Processamento Digital de Sinais em Hardware Reconfigurável*. A arquitetura, o núcleo de convolução `conv1d`, a integração do núcleo de FFT, o servidor em C e o cliente gráfico em Python são dele, e o projeto é distribuído sob a licença GNU GPL versão 3.

A partir de setembro de 2026 a plataforma foi continuada num estágio curricular no LabPS/UEFS, por Antonio Nicassio Santos Lima, sob supervisão do Prof. Armando S. Sanca. O objetivo do estágio foi tornar a plataforma reproduzível a partir do repositório e utilizável por uma turma de alunos que não conhece os detalhes de baixo nível. A Tabela 1.1 resume o que mudou; o registro dia a dia está em `docs/DIARIO.md` e as correções feitas no projeto original, com os motivos, em `docs/RESSALVAS.md`.

Tabela 1.1: O que o estágio acrescentou ao projeto original.

	Projeto original	Hoje
Tamanho	128 amostras na convolução e no FIR	1024 amostras em todas as operações, e sinais maiores por blocos
Operações Sinais	convolução, FIR, FFT gerados na janela	as três, mais IFFT e IIR gerados, lidos de arquivo, ou capturados pelo ADC da placa, à taxa escolhida
Filtros Precisão	sem projetista por especificação entrada da FFT sem normalização	projetistas FIR e IIR por especificação normalização da entrada: de 50 para 92 dB de SNR na FFT
Preparar a placa Laboratório	passos manuais, conhecidos pelo autor uma estação, uma placa	um comando, <code>morphe-up.sh</code> duas placas, vários clientes ao mesmo tempo, instalação para a turma e Quartus em todos os PCs
Reprodutibilidade	o que funcionava estava só na estação	tudo sai do repositório, com manifesto de integridade

1.4 Visão geral

A Figura 1.1 é a figura de referência deste manual: todo o resto detalha uma das partes dela.

Cada **PC do laboratório** roda o aplicativo Morphe, escrito em Python. Ele não precisa de nenhum software da Intel: fala com as placas só pela rede.

Cada **placa DE1-SoC** tem, no mesmo chip, um processador ARM rodando Linux (o HPS, *Hard Processor System*) e uma FPGA. No processador roda o `morphe_server`, que recebe as requisições pela rede na porta 5000; na FPGA estão os aceleradores que fazem as contas. Os dois lados conversam por pontes internas ao chip (seção 3.2).




Figura 1.1: Visão geral: os computadores do laboratório falam com as placas pela rede (TCP, porta 5000); a estação programa a FPGA pelo USB-Blaster e sobe o servidor por SSH.

A **estação** é o computador ligado às placas pelo cabo USB-Blaster. É dela que se roda o `morphe-up.sh`, que programa a FPGA pelo JTAG, compila e reinicia o servidor na placa por SSH e registra a placa para os clientes. A estação também roda o aplicativo, como qualquer outro PC.

1.5 Como ler este manual

Quem só vai **usar** a plataforma precisa do capítulo 7 (o aplicativo) e do capítulo 9 (preparar as placas). Quem vai **estender** a plataforma — acrescentar uma operação, mudar um acelerador, recompilar o hardware — deve ler os capítulos em ordem: a arquitetura (2), o hardware (3), o servidor (4), o protocolo (5) e a representação numérica (6) são o que se precisa saber antes de mexer em qualquer um deles.

Convenções usadas no texto:

- nomes de arquivos, comandos e sinais do hardware aparecem em **fonte monoespçada**; caminhos são relativos à raiz do repositório;
- endereços e constantes do hardware aparecem em hexadecimal, com o prefixo `0x`;
- $Q_{m.n}$ é um número em ponto fixo com sinal, m bits de parte inteira e n de parte fracionária (capítulo 6);
- todo número medido vem com a condição em que foi medido. Um número sem condição é de especificação, não de medida.

Capítulo 2

Arquitetura em três camadas

2.1 As camadas e o que cabe a cada uma

O Morphe se divide em três camadas, uma por máquina ou por tipo de circuito (Figura 2.1). Cada uma é escrita numa linguagem e tem uma responsabilidade que as outras não repetem.




Figura 2.1: As três camadas e os módulos de cada uma.

Tabela 2.1: Responsabilidades de cada camada.

	Faz	Não faz
Cliente Python, no PC	gera ou lê o sinal; projeta filtros; converte para ponto fixo; divide sinais longos em blocos; calcula a referência em ponto flutuante; compara e mostra	não sabe endereços de memória nem detalhes da FPGA
Servidor C, no HPS da placa	valida a requisição; copia os dados para as memórias da FPGA; dispara o acelerador; espera; devolve o resultado	não converte formatos numéricos (com uma exceção na FFT, seção 3.3.3); não guarda nada entre requisições
Aceleradores Verilog, na FPGA	fazem a conta, em ponto fixo, sobre blocos de tamanho fixo	não conhecem a rede nem o tamanho do sinal que o aluno pediu

Três princípios que atravessam as camadas

O servidor não guarda estado. Cada operação chega completa — os dados e todos os parâmetros — e sai completa. Não há sessão, reserva de placa nem memória da requisição anterior. É isso que permite que vários clientes usem a mesma placa intercalando operações, e que um cliente possa mudar de placa de uma operação para a outra sem nada a transferir.

O ponto fixo é decidido no cliente. O cliente converte o sinal para o formato do acelerador (Q15.16 ou Q15.8) antes de enviar, e converte o resultado de volta. O servidor copia inteiros de 32 bits sem interpretá-los, com uma única exceção: aplicar o expoente de bloco da FFT, que só ele conhece (seção 3.3.3). Fora isso, toda decisão numérica — normalizar a entrada, onde saturar, que fator aplicar à IFFT — mora num lugar só, em Python, onde é fácil de ler e de testar.

O hardware tem tamanho fixo; o software se adapta. Os aceleradores foram sintetizados para 1024 amostras. O servidor completa com zeros o que o cliente não mandou e devolve só as amostras que fazem sentido; o cliente, por sua vez, divide sinais maiores em blocos de 1024. Nenhum dos dois lados exige que o aluno pense em 1024.

Os números de configuração existem em dois lugares

Os limites do hardware — 1024 amostras, 16 seções de IIR, os bits fracionários de cada formato — estão escritos em `C/morphe_config.h`, para o servidor, e repetidos em `Python/morphe_config.py`, para o cliente. Os dois arquivos precisam mudar juntos. Os endereços das memórias e registradores, ao contrário, não são escritos à mão: vêm do `C/hps_0.h`, gerado a partir do projeto do hardware (seção 3.2).

2.2 O caminho de uma operação

A Figura 2.2 acompanha uma convolução do clique na janela até o gráfico. As outras operações seguem o mesmo roteiro, mudando só as memórias e o formato numérico.

1. **A janela entrega os sinais.** $x[n]$ e $h[n]$ chegam ao módulo de protocolo como vetores em ponto flutuante, do tamanho que o aluno escolheu.
2. **O cliente codifica.** Cada amostra vira um inteiro de 32 bits em Q15.16: $q = \text{round}(v \cdot 2^{16})$, saturado na faixa do formato. Se o sinal passa de 1024 amostras, a divisão em blocos acontece antes deste passo, e os passos seguintes se repetem por bloco.
3. **Uma conexão por operação.** O cliente abre uma conexão TCP com a placa, envia um cabeçalho de 20 bytes (operação, tipo dos dados, tamanhos) e os dados logo em seguida (capítulo 5).
4. **O servidor valida.** Confere a assinatura e a versão do protocolo, a operação, os tamanhos contra os limites do hardware e se a FPGA foi preparada pelo `morphe-up.sh` (capítulo 4). Qualquer falha vira uma resposta de erro com uma mensagem legível, e a FPGA não é tocada.
5. **O servidor escreve nas memórias.** Copia x e h para as memórias de entrada do acelerador, através da ponte HPS→FPGA, completando com zeros até 1024 amostras.
6. **O servidor dispara.** Escreve 1 no registrador `start` do acelerador, através da ponte leve. O acelerador detecta a subida desse sinal e começa.




Figura 2.2: O caminho de uma operação, do clique na janela ao gráfico.

7. **O acelerador calcula** e, ao terminar, leva o sinal **done** a 1. A convolução de 1024 por 1024 amostras leva cerca de 214 ms; a FFT de 1024 pontos, cerca de 21 ms (tempos de ida e volta medidos pelo `morphe_ping` em 15/09/2026, com a placa sem outros clientes).
8. **O servidor espera.** Lê o **done** a cada 50 μ s. Se ele não subir em 5 s, a operação é abandonada com o erro de tempo esgotado — o sintoma típico de um bitstream que parou de funcionar (seção 3.3).
9. **O servidor lê e responde.** Copia as $n_x + n_h - 1$ amostras úteis da memória de saída, devolve o **start** a 0 e envia o cabeçalho de resposta e os dados. Fecha a conexão.
10. **O cliente decodifica e compara.** Converte de volta para ponto flutuante, descarta o que for enchimento de zeros e calcula a referência em ponto flutuante com o NumPy. A janela mostra as duas e o erro entre elas.

Dois fatos decorrem desse roteiro e aparecem na prática.

O tempo de uma operação **não depende do tamanho do sinal pedido**: o acelerador sempre processa os blocos completos de 1024 amostras, e os zeros de enchimento custam o mesmo que amostras de verdade. Pela construção do `conv1d`, uma convolução de 10 por 10 amostras custa o mesmo que uma de 1024 por 1024.

Como o servidor atende **uma conexão de cada vez**, duas pessoas na mesma placa não recebem erro: a segunda espera a primeira terminar, e o tempo de cada uma soma. O capítulo 8 trata disso.

2.3 Onde está cada camada no repositório

Camada	Onde
Cliente	Python/ (aplicativo e módulos); testes em Python/ferramentas/
Servidor	C/ (<code>morphe_server.c</code> e cabeçalhos)
Aceleradores	Quartus/ (RTL, projeto do Platform Designer, bitstream)
Operação	<code>morphe-up.sh</code> , <code>instala-quartus.sh</code> , <code>deploy.sh</code> , na raiz

A árvore completa está no apêndice A.

Capítulo 3

O hardware

3.1 A placa DE1-SoC

A DE1-SoC, da Terasic, é construída em torno de um Cyclone V SoC da Intel (5CSEMA5F31C6). O “SoC” do nome quer dizer que o chip reúne duas coisas bem diferentes:

HPS (*Hard Processor System*): um processador ARM Cortex-A9 de dois núcleos, com memória e periféricos próprios, que roda um Linux gravado no cartão SD da placa. No Morphe ele cuida da rede e roda o servidor.

FPGA lógica programável, configurada pelo bitstream que o Quartus gera. No Morphe ela contém os aceleradores e as memórias em que eles trabalham.

Os dois lados estão no mesmo chip e se comunicam por pontes internas, sem passar por nenhum fio da placa. É essa proximidade que permite ao servidor escrever mil amostras numa memória da FPGA como se escrevesse num vetor em C.

A lógica da FPGA roda com o relógio de 50 MHz da placa (CLOCK_50). A análise de tempo da última compilação (24/09/2026, com o ADC) mede uma frequência máxima de 61,56 MHz para esse domínio: há folga de cerca de 20 %. A Tabela 3.1 mostra quanto do chip o projeto ocupa.

Tabela 3.1: Recursos da FPGA ocupados pelo projeto (compilação de 24/09/2026).

Recurso	Usado	Disponível	Ocupação
Elementos lógicos (ALMs)	12 621	32 070	39 %
Blocos DSP (multiplicadores)	30	87	34 %
Memória interna (bits)	2 220 342	4 065 280	55 %

A memória de captura do ADC, de 32 768 palavras, é o que fez a ocupação de memória subir de 42 % para 55 % em relação à compilação anterior (15/09/2026, sem o ADC). Ainda sobra quase metade.

O bitstream e a licença da FFT

O bitstream versionado é `Quartus/output_files/soc_system_time_limited.sof`, compilado com o Quartus Prime Lite 20.1. O núcleo de FFT é um IP da Intel que a edição Lite só permite usar em modo de avaliação: o bitstream funciona **enquanto o programador JTAG continuar conectado** à placa — o *tether* — e para depois de cerca de uma hora sem ele. Isso vale para o bitstream inteiro, não só para a FFT: sem o *tether*, a convolução também passa a esgotar o tempo. O `morphe-up.sh` mantém o *tether* vivo (capítulo 9).

3.2 Pontes e mapa de memória

O HPS enxerga a FPGA como faixas de endereços. O Morphe usa duas pontes (Figura 3.1):

Ponte HPS→FPGA (`h2f_axi_master`), a partir de `0xC000 0000`. Larga e rápida, é por onde passam os dados: as memórias de entrada e de saída de cada acelerador.

Ponte leve (*lightweight*), a partir de `0xFF20 0000`. Estreita, feita para registradores de controle: os PIOs de `start`, `done` e de parâmetros.

Ponte HPS→FPGA base 0xC000 0000, 32 bits		Ponte leve (LW) base 0xFF20 0000, PIOs	
0x10000	fir_yn	0x00	fir_error
0x12000	conv1d_yn	0x10	fir_done
0x14000	fir_hn	0x20	fir_start
0x15000	fir_xn	0x30	conv1d_done
0x16000	conv1d_hn	0x40	conv1d_start
0x17000	conv1d_xn	0x50	fft_bfp_exponent
0x18000	fft_yn_re	0x60	fft_wrapper_done
0x19000	fft_yn_imag	0x70	fft_inverse
0x1A000	fft_xn_re	0x80	fft_wrapper_start
0x1B000	fft_xn_imag	0x90	iir_start
0x1C000	iir_xn	0xA0	iir_done
0x1D000	iir_yn	0xB0	iir_error
0x1E000	iir_coef	0xC0	iir_nsecoes
0x20000	adc_buf	0xD0	adc_start
		0xE0	adc_done
		0xF0	adc_config
		0x100	adc_divisor
		0x110	adc_namostras
		0x120	adc_contador

convolução e FIR
 FFT e IFFT
 IIR
 ADC

Figura 3.1: Mapa de memória visto pelo servidor: memórias de dados atrás da ponte HPS→FPGA e registradores de controle atrás da ponte leve. Os endereços são deslocamentos a partir da base de cada ponte.

As memórias têm duas portas. Cada uma das catorze memórias de dados é uma RAM interna da FPGA de porta dupla: uma porta está ligada à ponte, para o HPS, e a outra ao acelerador (ou ao controlador do ADC). O servidor e o acelerador nunca disputam a mesma porta; o que os separa no tempo é o protocolo de `start` e `done` (seção 3.3). As memórias de entrada guardam 1024 palavras de 32 bits (4KB); as de saída da convolução e do FIR, 2047 (8KB); a de coeficientes do IIR, 5 palavras por seção para até 16 seções; a de captura do ADC, 32 768 palavras (128 KB).

Como o servidor chega lá. O servidor abre `/dev/mem` e mapeia as duas faixas no próprio espaço de endereços com `mmap`; a partir daí, escrever `g_conv_xn[i]` é escrever na memória da FPGA. Por isso ele precisa rodar como `root`. O tamanho da faixa mapeada é calculado em

tempo de compilação a partir do `hps_0.h`, e verificações estáticas no código recusam compilar se alguma memória for menor do que os limites de `morphe_config.h` exigem.

O `hps_0.h` é gerado, nunca editado. Os endereços da Figura 3.1 são decididos no Platform Designer, a ferramenta do Quartus que monta o sistema, e ficam registrados no arquivo `soc_system.sopcinfo`. O `Quartus/gen_hps_header.py` lê esse arquivo e escreve o `C/hps_0.h`; com `--check`, apenas confere se o cabeçalho versionado ainda corresponde ao projeto. Um servidor compilado com endereços velhos escreve nos lugares errados sem dar erro nenhum; a conferência existe para que isso não aconteça.

Cuidado com o mapa do “DE1-SoC Computer”. Os exemplos da Intel para a placa usam `0xC800 0000` como base da memória da FPGA. No Morphe a base é `0xC000 0000`. Código copiado desses exemplos lê e escreve fora das memórias do projeto (`docs/RESSALVAS.md`, item 11).

3.3 Os aceleradores

A Figura 3.2 mostra o que há dentro da FPGA: quatro aceleradores e o controlador de captura do ADC, cada um com as suas memórias e os seus registradores de controle, todos ligados ao HPS pela interconexão que o Platform Designer gera.




Figura 3.2: O que há dentro da FPGA: quatro aceleradores e o controlador do ADC, cada um com as suas memórias e os seus registradores de controle.

3.3.1 O protocolo comum

Todos os aceleradores obedecem ao mesmo combinado com o servidor:

1. com **start** em 0, o servidor escreve as entradas nas memórias;
2. o servidor leva **start** a 1; o acelerador detecta a *subida* do sinal, zera o **done** e começa;
3. o acelerador lê as entradas, calcula, escreve as saídas e leva **done** a 1;
4. o servidor, que lê **done** a cada 50 μ s, lê as saídas e devolve **start** a 0.

Como o acelerador reage à subida e não ao nível, um **start** esquecido em 1 não dispara uma segunda execução. E como o servidor zera todos os **start** na primeira requisição depois de a FPGA ser preparada, um valor que tenha sobrado de antes do bitstream do Morphe também não dispara nada.

Os aceleradores acessam as memórias por pequenos controladores que gastam alguns ciclos por acesso. É um custo deliberado de simplicidade: numa convolução, o tempo é dominado por esses acessos, não pela multiplicação. Os controladores estão em `memory_read_controller.v` e em `memory_write_controller.v`.

O tempo como sinal de saúde. Uma convolução de 1024 por 1024 amostras executa cerca de 8,4 milhões de ciclos, uns 168 ms a 50 MHz; de ponta a ponta, com a rede, o cliente mede 214 ms. Uma resposta muito mais rápida que isso é sinal de defeito, não de sorte: um bitstream mal compilado já foi visto levantar o **done** em 3,3 ms sem ter calculado nada (`docs/RESSALVAS.md`, item 13).

3.3.2 Convolução e FIR: o `conv1d`

O `conv1d.v` calcula a convolução linear

$$y[n] = \sum_k x[k] h[n - k], \quad n = 0, 1, \dots, 2046,$$

com os limites da soma ajustados a cada n para não ler fora dos vetores. É uma máquina de estados com um único multiplicador-acumulador: para cada n , lê $x[k]$ e $h[n - k]$, multiplica, acumula e, ao fim da soma, escreve $y[n]$.

A aritmética é em Q15.16. O produto de dois números de 32 bits tem 64 bits; o `conv1d` guarda os bits 47 a 16, o que realinha o ponto fracionário *truncando* os 16 bits de baixo. O acumulador tem 32 bits e *não satura*: quando a soma passa de ± 32768 ela dá a volta e aparece com o sinal trocado. Duas consequências práticas:

- o erro de truncamento se acumula com o número de termos: numa convolução de 1024 por 1024 ele chega a centenas de LSB. É esperado;
- com sinais de amplitude A e N termos, a saída estoura quando $NA^2 \geq 32768$ — com $N = 1024$, a partir de $A \approx 5,7$. Uma saída negativa para sinais positivos é esse estouro, não um defeito.

Trocar o truncamento por arredondamento reduziria o erro máximo medido de 521 para 25 LSB. A troca foi avaliada e **deliberadamente não feita** (14/09/2026): o comportamento numérico do `conv1d` é o que o TCC original descreve, e ele fica registrado em `docs/RESSALVAS.md` como escolha, não como defeito esquecido.

O FIR é o mesmo circuito. O filtro FIR é uma segunda instância do `conv1d` (`fir_inst`), com memórias próprias. Filtrar um sinal por um FIR é convoluí-lo com a resposta ao impulso do filtro, e é exatamente isso que acontece; a diferença entre as duas operações está no aplicativo, que oferece para o FIR um projetista de filtros. O projeto ainda contém um IP de FIR da Intel (`fir_ii`) e o seu adaptador, `fir_wrapper.v`, mas a instância está comentada no `ghrd_top.v`. O registrador `fir_error` sobrou desse adaptador e o `conv1d` não o aciona.

3.3.3 FFT e IFFT: o núcleo da Intel

A transformada usa o IP *FFT II* da Intel, configurado para 1024 pontos em modo *Buffered Burst*, com entrada de 24 bits e fatores de giro de 18 bits. O `fft_wrapper.v` faz a ponte entre as memórias e o IP: lê as partes real e imaginária da entrada, entrega-as ao IP amostra por amostra respeitando o *handshake* do barramento de fluxo, recebe o resultado e o escreve nas memórias de saída. O registrador `fft_inverse` escolhe entre a transformada direta e a inversa; o resto do caminho é o mesmo.

Duas particularidades desse núcleo aparecem no resultado:

Expoente de bloco. A cada estágio, o IP detecta se os valores cresceram e, se preciso, desloca as 1024 amostras *juntas*, acumulando um expoente único para o bloco (*block floating point*). O adaptador captura esse expoente no registrador `fft_bfp_exponent`, e o servidor o aplica, junto com o fator 2^{-8} do formato Q15.8, antes de devolver o resultado em ponto flutuante. É a única conversão numérica feita no servidor.

IFFT sem o fator $1/N$. O núcleo entrega a inversa não normalizada, N vezes a IDFT matemática. O cliente aplica o $1/1024$.

O capítulo 6 explica o que o expoente de bloco e os 24 bits de entrada significam para a precisão, e por que ela para em torno de 92 dB.

3.3.4 IIR: a cascata de seções de segunda ordem

O filtro IIR é a única operação em que a saída depende das saídas anteriores, e isso muda o que importa no projeto do circuito. Ele é implementado como uma cascata de até 16 seções de segunda ordem (*biquads*), cada uma em forma direta I (Figura 3.3):

$$y_s[n] = b_0 x_s[n] + b_1 x_s[n-1] + b_2 x_s[n-2] - a_1 y_s[n-1] - a_2 y_s[n-2],$$

com a saída de cada seção servindo de entrada para a seguinte. Os coeficientes vêm da memória `iir_coef`, cinco por seção, na ordem b_0, b_1, b_2, a_1, a_2 ($a_0 = 1$ fica implícito); o número de seções, do registrador `iir_nsecoes`.

Cada escolha desse projeto foi medida antes de ser feita:

Seções de segunda ordem, e não um polinômio de ordem N . A posição dos polos de um polinômio de ordem alta é extremamente sensível aos coeficientes. Um Butterworth de ordem 22, estável por construção, volta do próprio MATLAB com um polo de módulo 1,278 — instável — porque achar as raízes daquele polinômio já é mal condicionado em ponto flutuante de 64 bits. A mesma especificação em seções de segunda ordem tem o maior polo em 0,988.

Forma direta I. Tem um acumulador único e largo e arredonda uma vez só, na saída da seção. A forma direta II transposta, melhor em ponto flutuante, guarda estados já arredondados, e numa realimentação esse erro circula.




Figura 3.3: O bloco IIR: cascata de seções de segunda ordem (acima) e a seção em forma direta I (abaixo). Um só multiplicador-acumulador atende todas as seções, dois ciclos por seção.

Arredondar, e não truncar. Truncar introduz um viés de meio LSB negativo por amostra. Num filtro realimentado esse viés não some: vira um deslocamento DC de $-0,5/(1+a_1+a_2)$ LSB na saída. No FIR não importa, e por isso o `conv1d` pôde manter o truncamento.

Q15.16, o mesmo formato do `conv1d`. É suficiente: o raio dos polos se desloca no máximo cerca de 10^{-6} ao quantizar, mesmo com polos em $|p| = 0,9984$.

Uma amostra atravessa todas as seções antes da próxima. Assim bastam quatro registradores de estado por seção e uma única passagem pela memória. O resultado é idêntico, bit a bit, ao de processar seção por seção, porque cada seção só vê a saída já arredondada da anterior.

Um só multiplicador-acumulador, compartilhado. As cinco multiplicações de 32 por 32 bits de uma seção são feitas juntas, e o mesmo circuito atende as 16 seções em sequência. O custo em blocos DSP (15, porque cada multiplicação de 32 bits ocupa três multiplicadores de 27 bits) não depende do número de seções. Cada seção leva dois ciclos: um para selecionar os operandos, outro para calcular. Com um ciclo só, o circuito não fechava a 50 MHz (49,11 MHz medidos em 14/09/2026); com dois, fecha a 60,99 MHz.

Se alguma amostra satura, o registrador `iir_error` sobe; o resultado é devolvido mesmo assim, saturado, e o cliente avisa o aluno. O estado interno é zerado a cada execução, para que o mesmo sinal dê sempre a mesma saída.

Verificado bit a bit. O RTL do IIR tem um modelo de referência em Python que usa inteiros de precisão arbitrária (o acumulador de uma seção chega a 2^{65} , além do que um `float64` representa exatamente). O testbench em Icarus Verilog (`Quartus/roda_tb_iir.sh`) e a placa (`testa_iir_hw.py`) são comparados com esse modelo e precisam coincidir em todas as amostras: num filtro realimentado, divergir um LSB numa amostra é divergir para sempre dali em diante, então “parecido” não serve de critério.

3.4 A aquisição: o ADC da placa

A placa tem um conversor analógico-digital, e desde 24/09/2026 o Morphe o usa para capturar sinais. O aluno escolhe a taxa de amostragem, de 1 a 200 kHz, e o hardware a mantém constante durante a captura, amostra por amostra. A Figura 3.4 mostra o caminho, do conector até a memória que o servidor lê.




Figura 3.4: O caminho da aquisição: o controlador próprio dispara cada conversão do LTC2308 a $1/f_s$ e grava a amostra na memória de captura, que o servidor lê pela ponte.

3.4.1 O conversor e o conector

O conversor é o LTC2308, da Analog Devices (antiga Linear): 12 bits, 8 canais, por aproximações sucessivas, até 500 mil amostras por segundo, ligado à FPGA por uma interface serial de quatro fios (ADC_CONVST, ADC_SCLK, ADC_DIN, ADC_DOUT). A marca “2308” no chip ao lado do conector confirma o modelo; revisões antigas da DE1-SoC tinham outro conversor (AD7928), e o manual da placa de 2015 descreve esse, não o LTC2308.

As entradas chegam pelo conector J15, de 2×5 pinos. Pelo manual da placa (seção 3.6.12): pino 1 = 5 V, pino 2 = canal 0, pinos 3 a 9 = canais 1 a 7, pino 10 = terra. **Identifique os pinos medindo, e não olhando:** o conector já foi lido girado de 180° no laboratório, e o pino 1 fornece 5 V — ligado por engano ao terra, põe a alimentação em curto. Com o multímetro e a ponta comum na carcaça metálica do conector USB, o pino de 5 V e o de 0 V aparecem sem ambiguidade.

Faixa de tensão. Com a referência interna, a faixa de medida é de 0 a 4,095 V no modo de entrada simples (1 mV por passo) e de $-2,048$ a $+2,047$ V no modo diferencial, entre dois canais. Entre 4,096 V e cerca de 5,3 V a leitura só satura. **Abaixo de $-0,3$ V a entrada pode ser danificada**, e não há proteção entre o conector e o chip. Um sinal alternado do gerador de funções precisa de deslocamento DC: por exemplo, 2 V de deslocamento e no máximo 4 Vpp, conferido no osciloscópio *antes* de ligar à placa, com o terra do gerador no pino de terra do conector. A placa também não tem filtro *anti-aliasing*.

3.4.2 Por que um controlador próprio

O projeto original trazia o controlador do *University Program* da Intel para esse conversor, com a instância comentada. Ele converte sem parar, por conta própria, e entrega apenas o último valor lido de cada canal. Para ler uma tensão isso basta; para amostrar um sinal, não: o instante em que cada amostra foi tirada fica incerto em até uma volta inteira da varredura, alguns microssegundos. Essa incerteza vira ruído que cresce com a frequência do sinal — estimado em uns 25 dB de relação sinal-ruído para um tom de 5 kHz, contra os 74 dB que 12 bits permitem.

O Quartus/adc_captura.v substitui esse controlador. Um contador conta D ciclos de 50 MHz e, a cada volta, dispara uma conversão (a subida do CONVST). O instante da amostra é essa borda, com a precisão do relógio de 20 ns, e a taxa de amostragem é

$$f_s = \frac{50 \text{ MHz}}{D}, \quad 250 \leq D \leq 50\,000,$$

de 200 kHz a 1 kHz. Os 50 MHz são o relógio da FPGA, não a taxa de amostragem: quem decide a taxa é o aluno, na janela de aquisição. O cliente converte a f_s pedida no divisor inteiro mais próximo, $D = \text{round}(50 \text{ MHz}/f_s)$ (divisor_para em Python/aquisicao.py), e o envia

na requisição; o servidor o escreve no registrador `adc_divisor` antes de disparar. Como D é inteiro, a taxa real pode diferir um pouco da pedida (44,1 kHz vira 44 091,7 Hz), e é a taxa real que acompanha a captura.

A cada período o controlador:

1. mantém o `CONVST` alto por 96 ciclos (1,92 μ s, acima do tempo máximo de conversão);
2. gera 12 pulsos de relógio serial a 12,5 MHz, lendo os 12 bits do resultado e enviando, nos seis primeiros, a palavra de configuração da conversão seguinte (canal e modo);
3. grava a amostra na memória `adc_buf`, de 32 768 palavras.

O primeiro quadro de cada captura é descartado, porque a configuração enviada num quadro vale para a conversão seguinte. A taxa máxima de 200 kHz vem do tamanho do quadro, cerca de 150 ciclos, mais o tempo de aquisição que o conversor exige.

3.4.3 Captura única e captura contínua

O controlador tem dois modos, escolhidos pelo servidor:

Captura única grava $n \leq 32\,768$ amostras na memória e levanta o `done`. O servidor então lê tudo e responde.

Captura contínua grava sem parar, usando a memória como *buffer* circular, e mantém um contador (`adc_contador`) de quantas amostras já gravou. O servidor lê o contador, copia as amostras novas e as envia em blocos enquanto a captura segue (seção 5.5). Não há intervalo entre um bloco e outro, porque quem fixa o instante de cada amostra é o contador de período da FPGA, que não para.

Na captura contínua o limite passa a ser o servidor acompanhar: a memória guarda 164 ms de sinal a 200 kHz, e se o servidor atrasar mais que isso as amostras seriam sobrescritas antes de lidas. Isso nunca vira um buraco silencioso no sinal: o servidor relê o contador depois de cada cópia e, se o controlador já passou do ponto, termina a captura com o estado “perdeu”. O que foi enviado até ali é contínuo e válido. Medido em 24/09/2026, o HPS acompanha a taxa máxima: 2 milhões de amostras a 200 kHz, em 10 s, sem perda.

Tabela 3.2: Os registradores do controlador do ADC, na ponte leve, e a sua memória.

Nome	Endereço	Função
<code>adc_buf</code>	0x20000 (ponte HPS→FPGA)	32 768 palavras; 12 bits úteis cada
<code>adc_start</code>	0xD0	a subida dispara a captura; descer encerra a contínua
<code>adc_done</code>	0xE0	fim da captura única
<code>adc_config</code>	0xF0	bits 5–0: palavra do LTC2308 (canal, modo); bit 6: captura contínua
<code>adc_divisor</code>	0x100	D , de 250 a 50 000
<code>adc_namostras</code>	0x110	n da captura única
<code>adc_contador</code>	0x120	amostras já gravadas na contínua; 0 em repouso

3.4.4 O que foi validado

Em 24/09/2026, na placa 1, com o bitstream que contém o ADC: as operações que já existiam continuam iguais (testes da FFT, do IIR e dos blocos); a entrada ligada ao terra lê 0,0000 V, com desvio de 0,03 mV; ligada ao 3,3 V da própria placa, 3,3300 V, com desvio de 2,6 mV; a numeração dos canais e o modo diferencial estão certos; e a captura contínua acompanha 200 kHz. Com a entrada solta, a leitura fica perto de 1,9 V: é o próprio conversor carregando o pino, e não uma medida. **Falta a validação com uma senoide do gerador de funções** (capítulo 11).

Capítulo 4

O servidor na placa

O servidor é um programa em C, `C/morphe_server.c`, que roda no HPS de cada placa. Ele é a única parte do sistema que fala com a FPGA, e faz pouco: recebe uma requisição pela rede, confere, copia os dados para as memórias do acelerador, dispara, espera e devolve o resultado. Este capítulo descreve como ele faz isso e por que algumas das suas regras existem.

4.1 Estrutura

O programa tem um único fio de execução e atende **uma conexão por vez**. O laço principal é o mais simples possível:

1. abre o `/dev/mem` e mapeia as duas pontes (seção 3.2);
2. abre um *socket* TCP na porta 5000 (ou na que vier como argumento) com uma fila de espera de quatro conexões, `listen(srv, 4)`;
3. repete para sempre: `accept` → atende → `close`.

Atender uma conexão é ler o cabeçalho de 20 bytes, conferir a assinatura e a versão, e despachar pelo campo `opcode` para uma função por operação: `handle_conv`, `handle_fir`, `handle_fft`, `handle_ifft`, `handle_iir`, `handle_adc`, `handle_adc_continuo` e `handle_ping`. Um `opcode` desconhecido recebe o status `BAD_OPCODE`.

Não há *fork*, *threads* nem fila própria. Quem espera é o sistema operacional: enquanto uma operação está sendo atendida, as conexões seguintes ficam na fila do `listen`. Essa escolha é do projeto original e foi mantida porque é correta: a FPGA tem um acelerador de cada tipo, e duas operações ao mesmo tempo no mesmo acelerador seriam um erro. O que ela custa em latência quando vários alunos usam a mesma placa está medido no capítulo 8.

Uma função por operação, todas com o mesmo roteiro

Cada `handle_*` segue a mesma sequência, na mesma ordem:

1. confere se a FPGA foi preparada (seção 4.3); se não, recusa sem tocar em nada;
2. confere os tamanhos contra os limites de `morphe_config.h` e o tipo dos dados;
3. recebe o *payload* inteiro para um *buffer* local;
4. escreve nas memórias de entrada, **completando com zeros** até o tamanho do hardware;
5. leva o `start` a 0, espera 1 μ s, leva a 1;
6. espera o `done` (seção 4.2);

7. devolve o `start` a 0, lê as saídas e envia a resposta.

O enchimento com zeros do passo 4 não é detalhe: os aceleradores sempre processam o bloco inteiro de 1024 amostras, e o que tivesse sobrado na memória de uma operação anterior entraria na conta. No IIR isso apareceria como uma cauda na saída; na convolução, como amostras erradas no fim.

4.2 Esperar a FPGA

O servidor não usa interrupções. Depois do `start`, lê o registrador `done` a cada 50 µs até ele subir. Se não subir em **5 segundos**, a operação é abandonada, o `start` volta a 0 e o cliente recebe o status `FPGA_TIMEOUT`.

Nenhuma operação normal chega perto desse prazo: a mais longa, a convolução de 1024 por 1024 amostras, leva cerca de 170 ms na FPGA. Um tempo esgotado quer dizer que o acelerador não está funcionando, e na prática quase sempre tem uma de duas causas: o *tether* da licença caiu e o bitstream parou (seção 9.3), ou o servidor foi compilado com um `hps_0.h` que não corresponde ao bitstream carregado.

A exceção são as capturas do ADC, cuja duração depende do pedido — 32 768 amostras a 1 kHz levam 33 s. Nelas o prazo é calculado da própria captura: a duração esperada mais 2 s.

Cada operação registra no *log* os seus tempos em três fases — **entrada** (copiar para a FPGA), **fpga** (do `start` ao `done`) e **saida** (ler e enviar). O número do meio é o que interessa para diagnóstico: ele mede o hardware sozinho, sem a rede.

4.3 A marca de FPGA preparada

Esta é a regra mais importante do servidor, e a que custou mais caro para descobrir.

Quando uma DE1-SoC liga, o carregador de boot (U-Boot) programa a FPGA com o bitstream de fábrica gravado no cartão SD, o `soc_system.rbf`. Nesse bitstream os registradores e memórias do Morphe **não existem**. No Cyclone V, um acesso a um endereço sem escravo na ponte HPS→FPGA não devolve erro: **trava o barramento do processador inteiro**, sem prazo. A placa some da rede, e nem o console serial responde. Foi o que aconteceu com a placa 2 do laboratório a cada boot, entre 17 e 21/09/2026: o servidor subia sozinho no boot e zerava os registradores de `start` antes de a FPGA ter o bitstream do Morphe.

Desde então o servidor segue esta regra:

Nenhum acesso à FPGA enquanto não existir o arquivo
`/var/run/morphe-fpga-preparada`.

Quem cria esse arquivo é o `morphe-up.sh`, por SSH, logo depois de o programador do Quartus confirmar que gravou o bitstream do Morphe (capítulo 9). O `/var/run` é uma pasta em memória: o arquivo some sozinho no próximo boot, que é exatamente quando o U-Boot devolve a FPGA ao bitstream de fábrica. A marca e o bitstream que ela atesta desaparecem juntos.

Sem a marca, o servidor sobe normalmente, responde ao PING com `fpga_preparada=0` e recusa toda operação com o status `FPGA_NAO_PREPARADA` e a mensagem “rode `./morphe-up.sh` nesta placa”. Na primeira requisição depois que a marca aparece, e só então, ele zera os registradores de `start` de todos os aceleradores.

A segunda proteção: o `sysid`

O ADC trouxe uma variação do mesmo problema. Um servidor compilado com os endereços do ADC pode encontrar na FPGA um bitstream mais antigo, sem ele — por exemplo, se o

`morphe-up.sh` ainda não rodou depois de uma atualização. Os registradores do ADC não existiriam, e tocá-los travaria o barramento do mesmo jeito.

Todo bitstream do Morphe tem um componente `sysid` no mesmo endereço, com a data e hora em que o sistema foi gerado no Platform Designer. O `gen_hps_header.py` copia esse valor para o `hps_0.h` (`SYSID_QSYS_TIMESTAMP`). Antes de tocar em qualquer registrador do ADC, o servidor lê o `sysid` da FPGA e o compara com o do cabeçalho; se forem diferentes, recusa com a mensagem “o bitstream na FPGA não é o deste servidor”. O PING anuncia `adc_n_max=0` sempre que o ADC não pode ser usado.

Há ainda uma terceira camada, em tempo de compilação: o código do ADC só é compilado se o `hps_0.h` tiver a memória `adc_buf` (`MORPHE_TEM_ADC`). Um cabeçalho de antes do ADC produz um servidor que responde a essas operações com `BAD_OPCODE` e uma explicação.

4.4 Outros cuidados

Respostas de erro que chegam ao cliente. Quando o servidor recusa uma requisição, o cliente pode já ter enviado parte do *payload*. Fechar um *socket* com dados não lidos faz o Linux enviar um *reset* em vez de um fechamento normal, e o *reset* descarta a resposta que acabou de ser enviada: o cliente via “*connection reset by peer*” no lugar da mensagem de erro. Por isso, depois de toda resposta de erro, o servidor lê e descarta o que houver na entrada (`drain_pending`), com um limite de tempo e de tamanho.

Cliente que fecha a conexão no meio. Escrever num *socket* cujo outro lado fechou gera o sinal `SIGPIPE`, cuja ação padrão encerra o processo. Até 24/09/2026 um aluno que fechasse a janela durante uma operação longa derrubava o servidor da placa para todos. Agora o sinal é ignorado e o envio só devolve erro.

Pacotes de depuração. A cada operação o servidor grava, no seu diretório na placa, um pacote `.mrph` com a entrada e a saída (seção 7.5). Para não encher o cartão SD em silêncio, ele guarda os 100 mais recentes de cada tipo de operação e apaga os mais antigos. A variável de ambiente `MORPHE_DUMP_MAX` muda esse número; 0 desliga a gravação.

Modo de diagnóstico da FFT. Com `MORPHE_FFT_INVERSE=1` no ambiente, a operação FFT roda com o bit `inverse` ligado. Serviu para provar, em 10/09/2026, que esse bit estava vivo no hardware antes de existir a operação IFFT; não é usado na operação normal.

4.5 Compilação e início automático

O servidor é compilado **na própria placa**, com o `gcc` do Linux dela, pelo `C/Makefile`. As opções ativam as otimizações para o Cortex-A9 (`-O3`, `-mcpu=cortex-a9`, `-mfp=neon`). Os seis arquivos necessários — `morphe_server.c`, `morphe_protocol.h`, `morphe_config.h`, `hps_0.h`, `address_map_arm.h` e o `Makefile` — são enviados e compilados pelo `morphe-up.sh`, que re-compila com `make -B` sempre que algum deles mudou. Compilar à mão não é necessário, e o servidor precisa rodar como `root` por causa do `/dev/mem`.

No boot. O `C/autostart/instala-autostart.sh`, rodado uma vez em cada placa, registra o servidor como serviço do sistema (*systemd* ou *init.d*, o que a imagem do cartão tiver), com reinício automático se ele cair. Com o serviço instalado, a placa aparece na rede para os clientes assim que liga, recusando operações até ser preparada. Só o servidor de 21/09/2026 em diante pode ir para o início automático: o anterior tocava a FPGA ao subir.

4.6 Códigos de status

Toda resposta traz um status. Quando ele não é zero, o *payload* é uma mensagem em texto, que o cliente mostra ao aluno.

Tabela 4.1: Códigos de status das respostas (C/morphe_protocol.h).

Código	Nome	Quando aparece
0	OK	a operação foi feita
1	BAD_MAGIC	o cabeçalho não começa com MRPM: não é um cliente Morphe
2	BAD_VERSION	versão do protocolo diferente de 1
3	BAD_OPCODE	operação desconhecida, ou ADC pedido a um servidor compilado sem ele
4	BAD_DTYPE	tipo de dado que a operação não aceita (a FFT, a IFFT e o ADC só aceitam <code>int32</code>)
5	BAD_SIZE	tamanho fora dos limites do hardware, número de seções do IIR, taxa de amostragem ou configuração do ADC inválidos
6	FPGA_TIMEOUT	o acelerador não levantou o <code>done</code> no prazo (seção 4.2)
7	INTERNAL_ERROR	só no FIR, se o registrador <code>fir_error</code> estiver em 1; como nada no bitstream atual aciona esse registrador (seção 3.3.2), na prática não aparece
8	FPGA_NAO_PREPARADA	a placa não foi preparada pelo <code>morphe-up.sh</code> , ou o bitstream carregado não é o do servidor

Capítulo 5

O protocolo Morphe-TCP

Cliente e servidor conversam por um protocolo binário próprio, sobre TCP, na porta 5000. Ele é definido em dois arquivos que precisam concordar byte a byte: `C/morphe_protocol.h`, do lado do servidor, e `Python/morphe_protocol.py`, do lado do cliente.

5.1 Uma conexão por operação

Cada operação abre a sua própria conexão, e a conexão acaba com ela:

1. o cliente conecta;
2. envia um cabeçalho de requisição de 20 bytes e, logo em seguida, o *payload* com os dados;
3. o servidor responde com um cabeçalho de resposta de 20 bytes e o *payload* do resultado (ou uma mensagem de erro);
4. o servidor fecha a conexão.

Não existe sessão, autenticação nem estado guardado entre conexões. Isso é o que permite ao cliente escolher uma placa diferente a cada operação e a vários clientes intercalarem operações na mesma placa (capítulo 8). A única exceção ao roteiro é a captura contínua do ADC, em que a resposta é uma sequência de blocos enquanto a captura dura (seção 5.5).

5.2 Os cabeçalhos

Todos os campos são inteiros sem sinal em ordem de rede (*big-endian*). A Figura 5.1 mostra os dois cabeçalhos.




Figura 5.1: Os cabeçalhos de requisição e de resposta, em bytes.

magic a assinatura: 0x4D52504D (“MRPM”) na requisição e 0x4D52504E (“MRPN”) na resposta. Um servidor que recebe outra coisa responde **BAD_MAGIC** sem ler mais nada.

version sempre 1.

opcode a operação (Tabela 5.1); a resposta repete o da requisição.

dtype o tipo dos números no *payload*: 1 para **int32**, 2 para **float32**. Na prática o cliente sempre envia **int32** já em ponto fixo; o **float32** existe na convolução e no FIR por compatibilidade com o projeto original.

flags 0, exceto no ADC, em que carrega a palavra de configuração do conversor.

n_x, n_h os tamanhos. O significado muda com a operação: no IIR, **n_h** é o número de seções; no ADC, o divisor do relógio que dá a taxa de amostragem.

status 0 quando deu certo; os outros valores estão na Tabela 4.1. Com status diferente de zero, o *payload* é uma mensagem de texto de **n_out** bytes.

n_out quantos valores (ou bytes de mensagem) vêm no *payload* da resposta.

extra uma palavra livre para a operação: 1 no IIR se alguma amostra saturou; o divisor usado no ADC; 0 nas outras.

5.3 As operações

Tabela 5.1: As operações do protocolo e o que vai em cada *payload*. Todos os valores ocupam 4 bytes.

	Operação	Requisição	Resposta
1	CONV	n_x amostras de x , depois n_h de h , Q15.16; $1 \leq n_x, n_h \leq 1024$	$n_x + n_h - 1$ amostras de y , Q15.16
2	FFT	1024 amostras reais em Q15.8 ($n_x = 1024$)	1024 valores complexos em float32 , parte real e imaginária intercaladas, já em escala real
3	PING	nada	texto chave=valor , uma por linha (seção 5.4)
4	FIR	como a CONV: x e os coeficientes h	como a CONV
5	IFFT	1024 valores complexos em Q15.8, real e imaginário intercalados (2×1024 palavras)	como a FFT, sem o fator $1/N$
6	IIR	$n_x \leq 1024$ amostras em Q15.16, depois $5 \cdot n_h$ coeficientes Q15.16 na ordem b_0, b_1, b_2, a_1, a_2 de cada seção; $1 \leq n_h \leq 16$	n_x amostras Q15.16; extra = 1 se saturou
7	ADC	nada; $n_x =$ amostras (até 32768), $n_h =$ divisor, flags = configuração	n_x códigos do conversor, int32 ; extra = divisor
8	ADC_CONTINUO	como o ADC, com n_x sem limite (0 = até o cliente parar)	cabeçalho com $n_{out} = 0$ e depois blocos (seção 5.5)

Algumas observações sobre a tabela.

A FFT e a IFFT recusam tamanhos diferentes de 1024. A convolução completa com zeros o que faltar, porque acrescentar zeros ao fim de um sinal não muda a convolução. Com um espectro isso não vale: completar $X[k]$ com zeros muda o sinal que ele representa. Por isso as duas exigem exatamente 1024 pontos, e sinais de outros tamanhos são tratados no cliente (seção 7.6).

A FFT devolve números em ponto flutuante. É a única operação em que o servidor converte: ele conhece o expoente de bloco que o núcleo da FFT calculou (seção 3.3.3) e o aplica, junto com o fator 2^{-8} do Q15.8, antes de enviar. O cliente ainda desfaz a escala que ele mesmo aplicou na entrada (seção 6.3).

A IFFT recebe o dobro de dados. Um espectro é complexo por natureza, então o *payload* tem duas palavras por ponto. O servidor satura cada uma na faixa do Q15.8 antes de escrever na FPGA.

A palavra de configuração do ADC. São os seis bits que o LTC2308 recebe a cada conversão, na ordem da folha de dados: S/D, 0/S, S1, S0, UNI, SLP. Os quatro primeiros escolhem o canal e se a entrada é simples (contra o terra) ou diferencial (entre dois canais); UNI escolhe unipolar (0 a 4,095 V) ou bipolar ($\pm 2,048$ V). O modo de economia de energia (SLP) é recusado, porque a referência interna leva 200 ms para voltar dele. Quem monta a palavra é o Python/*aquisicao.py*; a janela só oferece o canal e o modo.

5.4 A descoberta: PING

O PING é só um cabeçalho, e a resposta é um texto curto que descreve a placa e o hardware que ela tem. Um exemplo, de uma placa preparada:

```
service=morphe
version=1
hostname=de1soc-02
fft_n=1024
conv_n_max=1024
iir_secoes_max=16
adc_n_max=32768
adc_fs_max=200000
uptime_s=5412
fpga_preparada=1
```

(a resposta completa traz mais alguns campos, como os bits fracionários de cada formato.) O cliente usa o PING para achar placas na rede e para conferir que uma placa está preparada (*fpga_preparada*); placas não preparadas não são escolhidas. O campo *adc_n_max* diz se o ADC pode ser usado naquela placa agora (0 quando não pode). O tempo que a resposta leva também é usado, para escolher a placa menos ocupada (capítulo 8).

5.5 A captura contínua do ADC

A captura contínua é a única operação cuja resposta não cabe numa mensagem só: ela pode durar minutos, e o sinal é enviado enquanto é capturado. Depois do cabeçalho de resposta (com *status* 0, $n_{out} = 0$ e o divisor em *extra*), vem uma sequência de blocos, cada um com o formato

$$\underbrace{\quad}_\text{uint32} \quad \underbrace{\quad}_\text{uint32} \quad \underbrace{c_0 \ c_1 \ \dots \ c_{n-1}}_{n \times \text{int32}}$$

O *estado* de cada bloco é 0 enquanto a captura segue. O último bloco tem $n = 0$ e um estado que diz por que ela terminou:

Estado	Significado
1	fim normal: chegou ao total pedido, ou o cliente pediu para parar
2	o servidor não acompanhou e amostras foram perdidas; o que veio antes vale
3	o hardware parou de produzir amostras

Os blocos são contínuos no tempo: a última amostra de um e a primeira do seguinte estão separadas por exatamente um período de amostragem. Para parar a captura antes do total, o cliente envia um byte qualquer pela mesma conexão (é o que o botão *Parar* faz), ou simplesmente a fecha. Como funciona do lado do hardware está na seção 3.4.

5.6 Como acrescentar uma operação

Uma operação nova toca sempre os mesmos lugares, e esquecer qualquer um deles produz um erro que não aponta para a causa:

1. `C/morphe_protocol.h`: o número da operação (`MORPHE_OP_*`) e, no comentário do topo, o formato do *payload*;
2. `C/morphe_server.c`: a função `handle_*`, seguindo o roteiro do capítulo 4 — a primeira linha confere a marca de FPGA preparada — e o seu `case` no `serve_connection`;
3. `Python/morphe_protocol.py`: a constante `OP_*`, a função `build*_request` e a `decode*_response`;
4. `C/morphe_config.h` e `Python/morphe_config.py`, juntos, se a operação tiver limites próprios;
5. se a operação usa hardware novo: o Platform Designer, o `hps_0.h` regenerado e um bitstream novo (capítulo 10).

Mudar o formato de uma operação que já existe, em vez de criar outra, quebra os clientes instalados nos PCs até que sejam atualizados. Se for inevitável, o lugar de sinalizar é o campo `version`.

Capítulo 6

Representação numérica

Tudo o que a FPGA calcula é em ponto fixo, e a diferença entre esse cálculo e o do computador é o que o Morphe existe para mostrar. Este capítulo reúne o que se sabe sobre essa diferença: os formatos usados, a regra que governa o erro, o que o núcleo da FFT faz por dentro e os números medidos na placa. A versão com todas as medições está em `docs/PRECISAO-NUMERICA.md`.

6.1 Os dois formatos

O Morphe usa **dois** formatos de ponto fixo, um para cada família de aceleradores (Figura 6.1). Os dois têm a mesma faixa, mas passos muito diferentes, e confundi-los é o erro mais comum de quem mexe no código.




Figura 6.1: Os dois formatos de ponto fixo, bit a bit.

Tabela 6.1: Os formatos de ponto fixo e onde cada um é usado.

Formato	Bits	Passo Δ	Faixa	Usado em	Por quê
Q15.8	24	$2^{-8} \approx 3,9 \times 10^{-3}$	± 32768	FFT, IFFT	o núcleo da Intel lê 24 bits
Q15.16	32	$2^{-16} \approx 1,5 \times 10^{-5}$	± 32768	conv., FIR, IIR	multiplicadores próprios, de 32 bits

A codificação é a mesma para os dois, feita no cliente:

$$q = \text{round}(v \cdot 2^f),$$

com f o número de bits fracionários, saturando na faixa do formato. No Q15.8 o valor ocupa os 24 bits de baixo de uma palavra de 32, com o bit de sinal repetido nos 8 de cima para que o HPS leia o número certo; o núcleo da FFT ignora esses 8 bits. As funções estão em `Python/dsp_core.py` (`fft_q1508_encode` e `float_to_q1516`).

6.2 A regra dos 6 dB por bit

O arredondamento comete um erro distribuído uniformemente entre $-\Delta/2$ e $+\Delta/2$, com variância $\Delta^2/12$. Se o sinal for multiplicado por um fator s antes de codificar e dividido por s depois, o passo efetivo passa a ser Δ/s , e a relação sinal-ruído melhora em

$$20 \log_{10} s \text{ dB}, \quad \text{ou seja, } 6,02 \text{ dB a cada vez que } s \text{ dobra.}$$

Numa operação linear — a FFT, a IFFT, a convolução — essa escala se desfaz exatamente na saída, então o ganho é de graça. O quanto se pode ganhar depende da faixa que o sinal deixa sem uso:

$$\text{ganho máximo} = 6,02 \cdot \log_2 \frac{32\,768}{\max |v|} \text{ dB.}$$

Um sinal de amplitude 3 codificado numa faixa que vai a 32 768 desperdiça cerca de 13 bits.

Medido na placa. A Tabela 6.2 mostra a mesma FFT de um sinal de pico 3,3 feita com escalas crescentes, comparada com a do NumPy. De 1 a 64 são 6 bits: a teoria prevê 36,1 dB de ganho, e a placa deu 36,2 dB.

Tabela 6.2: FFT de um sinal de pico 3,3 com escalas crescentes, comparada com `np.fft.fft` (placa, 10/09/2026).

Escala	Pico de x	SNR	Ganho
1	3,3	50,42 dB	—
4	13,2	62,74 dB	+12,32 dB
16	52,8	75,07 dB	+24,65 dB
64	211,1	86,64 dB	+36,22 dB
256	844,3	91,74 dB	+41,33 dB
1024	3 377,3	91,66 dB	+41,24 dB
4096	13 509,1	91,55 dB	+41,13 dB

Acima da escala 256 a melhora para, em cerca de **92 dB**. A partir daí o limite deixa de ser o Q15.8 da entrada e passa a ser a aritmética interna do núcleo da FFT, explicada na seção 6.4.

6.3 A normalização da entrada

Por causa dessa regra, o cliente **normaliza** a entrada da FFT e da IFFT por padrão: multiplica o sinal pelo fator que o leva a 98 % da faixa do Q15.8, envia, e divide o resultado pelo mesmo fator. As janelas têm uma caixa “Normalizar entrada”, ligada, que permite desligar e ver a diferença.

Tabela 6.3: Efeito da normalização, medido na placa (10/09/2026).

Operação	Sem normalizar	Normalizada	Escala usada
FFT, sinal de pico 3,3	50,42 dB	91,53 dB	9 737
IFFT, espectro de pico 1280	91,17 dB	92,69 dB	25,09

A IFFT ganha pouco *neste* espectro porque ele já ocupava bem a faixa. O caso em que ela é decisiva é o contrário, e ele é comum. O espectro de um sinal pode ser até N vezes maior que o sinal:

$$|X[k]| \leq \sum_n |x[n]| \leq N \cdot \max |x[n]|,$$

ou seja, até 60 dB acima, com $N = 1024$. Um espectro assim satura o Q15.8 nos picos; um espectro pequeno tem os seus pontos menores abaixo de $\Delta/2 = 1/512$, e eles viram exatamente zero. Normalizado, um espectro 10^4 vezes menor volta com erro de $5,9 \times 10^{-8}$, contra $2,7 \times 10^{-3}$ sem normalizar.

6.4 O que o núcleo da FFT faz por dentro

O núcleo *FFT II* da Intel está configurado com entrada de 24 bits, fatores de giro de 18 bits e *ponto flutuante em bloco*. A FFT de 1024 pontos tem cinco estágios de base 4 ($1024 = 4^5$). A cada estágio o núcleo verifica se os valores cresceram e, se preciso, desloca **as 1024 amostras juntas**, acumulando um expoente único para o bloco:

$$y = y_{\text{bruto}} \cdot 2^{-e}.$$

O adaptador captura e e o servidor o aplica (seção 3.3.3). Duas consequências:

1. o ponto flutuante em bloco **não recupera** o que se perdeu na entrada. Um valor que ficou abaixo de $1/512$ já era zero antes de o núcleo começar. Por isso a normalização continua valendo 6 dB por bit;
2. o expoente é **compartilhado**. Os pontos do espectro muito abaixo do pico carregam menos bits efetivos, porque o deslocamento foi decidido pelo maior deles. Isso, junto com os fatores de giro de 18 bits, é o que põe o teto em cerca de 92 dB.

A normalização do cliente e o ponto flutuante em bloco resolvem problemas diferentes: a primeira posiciona o sinal *antes* de ele virar 24 bits; o segundo evita que ele estoure *durante* a transformada. Um não substitui o outro.

A IFFT não aplica o $1/N$. O núcleo entrega N vezes a IDFT matemática. Isso foi medido, não suposto: enviando um sinal real pelo caminho da FFT com o bit **inverse** ligado, a magnitude do que volta é a da DFT (razão 1,00031), e para x real $\text{IDFT}(x) = \overline{\text{DFT}(x)}/N$. O cliente aplica o $1/1024$ (`IFFT_HW_GAIN` em `morphe_config.py`), e o resultado coincide com o `idft.m` do Prof. Sanca a $2,5 \times 10^{-5}$.

6.5 Convolução, FIR e IIR

Os aceleradores em Q15.16 têm comportamentos numéricos próprios, descritos com o circuito no capítulo 3. Em resumo:

Convolução e FIR *truncam* cada produto e acumulam em 32 bits *sem saturar*. O erro de truncamento cresce com o número de termos (chega a centenas de LSB em 1024 por 1024), e uma soma além de $\pm 32\,768$ dá a volta com o sinal trocado (seção 3.3.2).

IIR *arredonda* na saída de cada seção e *satura* em vez de dar a volta; o registrador `iir_error` avisa quando saturou. O resultado da placa coincide bit a bit com o modelo em Python (seção 3.3.4).

Os coeficientes dos filtros também são quantizados. Um FIR projetado em ponto flutuante e convertido para Q15.16 muda cada coeficiente em no máximo meio passo ($7,6 \times 10^{-6}$, medido). No IIR, com os polos em seções de segunda ordem, o raio de cada polo se desloca no máximo cerca de 10^{-6} , mesmo com polos em $|p| = 0,9984$. É isso que torna o Q15.16 suficiente para os dois.

6.6 O ADC

O conversor da placa tem 12 bits: 4096 níveis de 1 mV entre 0 e 4,095 V (ou entre $-2,048$ e $+2,047$ V no modo diferencial). O ruído de quantização de um conversor ideal de B bits, com uma senoide que ocupa a faixa inteira, dá uma relação sinal-ruído de

$$\text{SNR} = 6,02 B + 1,76 \text{ dB} \approx 74 \text{ dB} \quad (B = 12).$$

O número de bits efetivos (ENOB) que a janela de aquisição mostra é essa fórmula invertida, aplicada à relação medida: $\text{ENOB} = (\text{SINAD} - 1,76)/6,02$. A medida usa a janela de Blackman-Harris, e não a de Hann: com a de Hann o vazamento espectral limitava a medida a cerca de 53 dB e escondia o conversor.

Uma senoide que ocupa só uma parte da faixa perde o mesmo que um sinal mal escalado na FFT: 6 dB a cada vez que a amplitude cai pela metade. Por isso a recomendação de usar amplitude perto de 2 V de pico em torno de 2 V de deslocamento (seção 3.4).

6.7 Números para referência rápida

Tabela 6.4: Erros medidos na placa, para comparação.

Medida	Valor	Condição
FFT $\rightarrow$ IFFT $\rightarrow$ sinal original, erro máximo	$6,1 \times 10^{-5}$	as duas normalizadas
FFT $\rightarrow$ IFFT, erro máximo	$9,5 \times 10^{-4}$	nenhuma normalizada
FFT contra o NumPy	91,5 dB	normalizada
IFFT contra o NumPy	92,7 dB	normalizada, espectro de pico 1280
Convolução 1024×1024 , erro máximo	521 LSB	truncamento
IIR contra o modelo em Python	0 LSB	qualquer filtro testado
Coefficientes FIR, ponto flutuante contra Q15.16	$\leq 7,6 \times 10^{-6}$	meio passo
ADC, entrada no terra	0,0000 V, desvio 0,03 mV	24/09/2026
ADC, entrada no 3,3 V da placa	3,3300 V, desvio 2,6 mV	24/09/2026

6.8 Regras práticas

1. Antes de codificar, olhe $\max |v|/32768$. Se for muito menor que 1, há bits sendo jogados fora.
2. Numa operação linear, normalize: a escala se desfaz exatamente.
3. Não espere mais que cerca de 92 dB de nada que passe pelo núcleo da FFT. Um erro de ida e volta de 10^{-5} não é defeito, é esse teto.
4. Um espectro não pode ser completado com zeros como um sinal no tempo.
5. Erro grande e sistemático é escala errada; erro pequeno e espalhado é quantização.
6. Na convolução, saída negativa para entradas positivas é estouro do acumulador, não defeito: reduza a amplitude.

Capítulo 7

O aplicativo cliente

O aplicativo é o que o aluno vê. Escrito em Python, com Tkinter para as janelas e Matplotlib para os gráficos, roda em qualquer PC do laboratório e não precisa de nenhum software da Intel. As dependências são o NumPy e o Matplotlib; o SciPy é opcional e só é usado pelo projeto de filtros IIR elípticos.

7.1 Abrir o aplicativo

Na instalação de turma (capítulo 9):

```
cd /opt/morphe/Python && python3 morphe_app.py
```

A janela principal abre já procurando a placa. Primeiro tenta as placas que o `morphe-up.sh` registrou em `.morphe-estado/placas`; se houver mais de uma, sonda todas e fica com a menos ocupada (capítulo 8). Sem lista, varre a rede local. O painel de conexão no topo mostra a placa escolhida ou, depois de uns seis segundos sem achar nenhuma, diz isso em silêncio, sem janela de erro: o gerador de sinais, o comparador e os projetistas de filtro funcionam sem placa. O mesmo painel permite digitar um endereço à mão.

7.2 As janelas

A janela principal é um menu de botões, um por ferramenta:

Gerador de Sinais monta um sinal e o mostra, sem placa. Serve para explorar e para salvar sinais em arquivo.

Aquisição (ADC da placa) lê tensões e captura sinais pela entrada analógica da placa (seção 7.3).

Convolução dois sinais, $x[n]$ e $h[n]$, convoluídos na FPGA. Mostra as entradas, a saída da placa, a referência do NumPy e o erro entre elas.

FFT um sinal, transformado na FPGA; mostra magnitude e fase, compara com o NumPy e permite voltar ao tempo pela IFFT da própria placa.

IFFT um espectro lido de arquivo (`.mrph`, `.npz` complexo ou texto com colunas real e imaginária), transformado de volta na FPGA. Serve para testar a inversa isolada do erro da direta.

Filtro FIR um sinal montado por superposição de componentes, filtrado na FPGA por um FIR que vem do projetista ou de um arquivo de coeficientes.

Filtro IIR a mesma ideia, com um IIR em seções de segunda ordem. O gráfico do meio é a resposta em frequência do projeto e do filtro quantizado. A saída da placa é conferida na hora, bit a bit, contra o modelo em ponto fixo, e a barra de status diz se bateu.

Comparar .mrph abre um pacote salvo (seção 7.5) e refaz a conta no computador, sem placa.

Todas as janelas que usam a placa têm a mesma estrutura: um painel para o sinal de entrada, um botão que envia à FPGA, os gráficos (com barra de ferramentas para ampliar, deslocar e destacar o gráfico numa janela própria) e uma barra de status que diz o que aconteceu, inclusive o tempo que a placa levou.

Existe também uma janela de espectrograma, pronta e validada, que ficou fora do menu por decisão do supervisor; as linhas que a ligam estão comentadas no `morphe_app.py`, com a marca ESPECTROGRAMA.

De onde vem o sinal

O painel de sinal de todas as janelas oferece sete tipos:

- cinco gerados: degrau, impulso, senoide, exponencial e retangular, com os seus parâmetros e o número de amostras N ;
- **Arquivo:** um sinal qualquer, lido de `.csv`, `.txt`, `.npy` ou `.wav`. Texto com uma coluna (as amostras) ou duas (índice ou tempo, amostra), com vírgula, ponto e vírgula, tabulação ou espaços; aceita a vírgula decimal de planilhas em português. Do `.wav` vem também a taxa de amostragem. O leitor está em `Python/sinal_arquivo.py`;
- **Captura do ADC:** a última captura feita na janela de aquisição.

Com os dois últimos o tamanho do sinal é o do arquivo ou da captura, e pode passar muito de 1024 amostras: as janelas então processam por blocos (seção 7.6). Quando o sinal vem com uma taxa de amostragem e o filtro foi projetado com outra, as janelas do FIR e do IIR avisam. `exemplos/sinais/` tem arquivos de exemplo para cada janela, com um `README.md`.

Os projetistas de filtros

FIR. O projetista (`fir_design.py`) tem dois modos. *Por especificação*, o padrão: o aluno dá o tipo (passa-baixa, passa-alta, passa-banda, rejeita-banda), a borda da banda passante, a largura da transição, o *ripple* e a atenuação; o programa escolhe a janela (retangular, Hann, Hamming, Blackman ou Kaiser) e calcula quantos coeficientes são necessários. É o método do `dsp_fir_filter.m` do Prof. Sanca, portado para Python. No modo *avançado*, o aluno escolhe o número de coeficientes e a janela. Nos dois, o projetista mostra o que o filtro entrega *depois* da quantização em Q15.16. Validado na placa em 22/09/2026: 63,0 dB de rejeição medida contra 63,3 dB da referência.

IIR. O projetista (`iir_design.py`) segue o `dsp_iir_filter.m` do Prof. Sanca: Butterworth, Chebyshev I, Chebyshev II e elíptico, nos quatro tipos. A diferença deliberada é a saída: em vez de um polinômio de ordem N , ela é uma cascata de seções de segunda ordem, pelos motivos da seção 3.3.4. O Butterworth e os dois Chebyshev são calculados só com NumPy; o elíptico usa o SciPy e só aparece se ele estiver instalado. Quatro erros encontrados no `.m` original estão corrigidos no módulo Python e documentados nele.

7.3 A janela de aquisição

A janela “Aquisição (ADC da placa)” depende de a placa ter o bitstream com o ADC; se não tiver, a própria mensagem de recusa do servidor aparece na barra de status (seção 4.3). Ela faz duas coisas.

Voltímetro. Lê a tensão média de 0,1 s na entrada escolhida, com desvio, mínimo e máximo, e pode repetir sozinho para acompanhar um ajuste. Não há hardware separado para isso: é uma captura de 2000 amostras a 20 kHz. O intervalo de 0,1 s contém um número inteiro de ciclos de 50 Hz e de 60 Hz, então a média cancela o zumbido da rede elétrica.

Captura. O aluno escolhe a entrada (um dos oito canais contra o terra, de 0 a 4,095 V, ou um dos quatro pares diferenciais, de $\pm 2,048$ V), a taxa de amostragem (de 1 a 200 kHz) e o número de amostras:

- até 32 768, a captura é de uma vez, na memória da FPGA;
- acima disso, ou com 0 amostras (sem limite, até clicar em *Parar*), é contínua: a placa envia em blocos enquanto captura (seção 5.5).

O gráfico mostra o sinal em volts; acima de 200 mil pontos, a envoltória. Para uma senoide, a janela mede frequência, SINAD e ENOB, que é o jeito de conferir o conversor com um gerador de funções (seção 3.4). A captura pode ser salva em `.csv`, `.npy` ou `.wav` e passa a estar disponível como o tipo “Captura do ADC” em todas as outras janelas. As contas — a palavra de configuração, a taxa real, a conversão para volts, as métricas e a gravação — estão em `Python/aquisicao.py`, separadas da janela.

A taxa real é 50 MHz/divisor, com divisor inteiro. Ela é exata para as taxas que dividem 50 MHz; as outras são arredondadas, e a janela mostra a taxa real usada (44,1 kHz, por exemplo, vira 44 091,7 Hz).

7.4 Os módulos

As janelas são finas; o que importa está nos módulos que elas usam.

7.5 O pacote `.mrph` e o comparador

O `.mrph` é o formato de arquivo do Morphe: texto puro, legível em qualquer editor. Um arquivo simples tem um cabeçalho com linhas iniciadas por `#` (data, tipo numérico, tamanho, taxa de amostragem, descrição) e uma tabela de valores, com duas colunas para sinais reais (n , valor) e três para complexos (k , real, imaginário). Um *pacote* reúne vários sinais num arquivo só, em seções iniciadas por `## section:`, cada uma com o seu cabeçalho: numa convolução, x , h e y ; numa FFT, x e X .

Os pacotes vêm de dois lugares: as janelas salvam o que o aluno fez, e o servidor grava um a cada operação na placa (seção 4.3 e seguinte). O comparador abre qualquer um deles, identifica a operação, refaz a conta em NumPy (no IIR, no modelo em ponto fixo) sobre a mesma entrada e mostra a diferença. É o caminho para estudar um resultado depois, sem placa, ou para investigar um resultado estranho que um aluno trouxe. `exemplos/` tem pacotes reais produzidos pela placa.

Tabela 7.1: Os módulos do cliente, em Python/.

Módulo	O que faz
morphe_app.py	a janela principal e o menu
*_window.py	uma janela por ferramenta
signal_panel.py	o painel de sinal comum a todas as janelas
tcp_panel.py	o painel de conexão: descoberta e escolha da placa
morphe_protocol.py	o protocolo (capítulo 5): monta e decodifica as mensagens, abre as conexões, varre a rede
morphe_config.py	os limites do hardware, espelho do C/morphe_config.h
dsp_core.py	geração de sinais, conversão para ponto fixo, a referência em ponto flutuante e a leitura e escrita de .mrph
blocos.py	o processamento de sinais maiores que o hardware (seção 7.6)
sinal_arquivo.py	a leitura de sinais de arquivo
aquisicao.py	as contas do ADC
fir_design.py, iir_design.py	os projetistas, e o modelo em ponto fixo do IIR que reproduz a placa bit a bit
morphe_theme.py, plot_toolbar.py, popout_helper.py	aparência, barra dos gráficos, gráficos em janela própria
morphe_export.py	exporta uma janela aberta para SVG vetorial, para figuras de artigos e deste manual

7.6 Sinais maiores que o hardware: processamento em blocos

Os aceleradores processam no máximo 1024 amostras por vez. Um arquivo de áudio de um segundo tem 44 100; uma captura do ADC pode ter milhões. O Python/blocos.py divide o sinal em blocos, manda cada um à placa pelo mesmo caminho que as janelas usam para um bloco só, e junta os resultados. São três técnicas, uma por tipo de operação, e cada uma tem um argumento de por que o resultado é o mesmo que uma operação única daria.

Todas as funções de bloco recebem a operação de *um* bloco como parâmetro: na placa, as classes ConvPlaca, FirPlaca, FftPlaca, IfftPlaca e IirPlaca; nos testes sem placa, o np.convolve, o np.fft.fft e o modelo em ponto fixo. Isso permite conferir a montagem dos blocos separada do hardware.

7.6.1 Convolução e FIR: *overlap-add*

A convolução é linear e invariante no tempo. Cortando x em blocos x_i de L amostras,

$$x[n] = \sum_i x_i[n - iL] \implies (x * h)[n] = \sum_i (x_i * h)[n - iL].$$

Cada $x_i * h$ é uma convolução que cabe na placa, com $L + M - 1$ amostras de saída; as caudas de $M - 1$ amostras de blocos vizinhos se sobrepõem e são somadas (Figura 7.1). Se h também passa de 1024 amostras, é cortado do mesmo jeito, e cada par de pedaços vira uma requisição. O resultado é exatamente a convolução linear: a única diferença para uma operação única é a quantização em Q15.16, que já existia.

7.6.2 FFT e IFFT: o algoritmo de quatro passos

Uma DFT de $N = M \cdot 1024$ pontos se decompõe em DFTs de 1024 e DFTs de M pontos, ligadas por fatores de giro. É a decomposição de Cooley–Tukey com $N_1 = M$ e $N_2 = 1024$. Com





Figura 7.1: *Overlap-add*: cada bloco de L amostras é convoluído na placa; as caudas de $M - 1$ amostras se somam.

$n = n_1 + Mn_2$ e $k = 1024k_1 + k_2$:

$$X[1024k_1 + k_2] = \sum_{n_1=0}^{M-1} W_M^{n_1k_1} W_N^{n_1k_2} \underbrace{\text{FFT}_{1024}\{x[n_1 + Mn_2]\}}_{\text{na placa}}[k_2].$$

Em quatro passos (Figura 7.2):

1. a placa faz M FFTs de 1024 pontos, uma por subsequência $x[n_1], x[n_1 + M], x[n_1 + 2M], \dots$;
2. cada resultado é multiplicado pelos fatores de giro $W_N^{n_1k_2}$;
3. o PC faz 1024 DFTs de M pontos, uma por coluna k_2 ;
4. a matriz resultante, lida por linhas, é $X[k]$ na ordem natural.



Não é aproximação: é a DFT de N pontos com a conta dividida (Cooley–Tukey com $N_1 = M$, $N_2 = 1024$). A IFFT longa usa a mesma decomposição, com os fatores conjugados e $1/N = 1/1024 \cdot 1/M$.

Figura 7.2: FFT de $N = M \cdot 1024$ pontos pelo algoritmo de quatro passos: M FFTs de 1024 na placa, fatores de giro e DFTs de M pontos no PC.

Não é uma aproximação: é a mesma DFT, com a conta dividida. A precisão é a das FFTs da placa, cada uma normalizada por conta própria, mais a do ponto flutuante de 64 bits do PC, desprezível perto dela. O sinal é completado com zeros até o múltiplo de 1024 acima. A IFFT longa é a mesma decomposição no sentido inverso, e por isso exige que o espectro já tenha um número de pontos múltiplo de 1024.

A escolha foi deliberada: um espectrograma (FFTs de quadros sobrepostos) também processaria sinais longos, mas mudaria o significado da janela da FFT, que é mostrar a transformada do sinal.

7.6.3 IIR: blocos com aquecimento

O IIR não se decompõe assim. A saída em n depende de toda a entrada anterior, e o bloco da placa sempre começa com o estado zerado. A solução é a usual: cada bloco começa A amostras *antes* do trecho que interessa, e as primeiras A saídas são descartadas (Figura 7.3). Se o aquecimento for longo o bastante para o transitório do estado zero morrer, o trecho guardado coincide com o do filtro rodando sem parar.




Figura 7.3: IIR por blocos: cada bloco começa algumas amostras antes (*aquecimento*) e essa parte da saída é descartada.

O aquecimento é calculado pelo polo de maior módulo $|p|$: o transitório decai como $|p|^n$, e o critério é ele cair abaixo de meio passo do Q15.16,

$$A = \left\lceil 1,5 \cdot \frac{\ln 2^{-17}}{\ln |p|} \right\rceil + 8 \cdot (\text{número de seções}),$$

com a folga de 50 % e o termo por seção cobrindo os polos repetidos. Um filtro com polos muito perto do círculo unitário pode precisar de um aquecimento maior que o próprio bloco; nesse caso o cliente recusa com uma mensagem que explica por quê.

Para a conferência bit a bit da janela continuar valendo, o modelo em Python roda com *os mesmos blocos*: placa e modelo batem exatamente. A distância entre os blocos e o filtro contínuo é medida à parte e mostrada em LSB. Em ponto fixo ela nem sempre chega a zero, porque o arredondamento na realimentação pode fazer estados iniciais diferentes convergirem para bits diferentes: medido em 23/09/2026, 0 LSB num Butterworth de ordem 4 com corte em 1 kHz e 4 a 8 LSB num de ordem 2 com corte em 100 Hz, ambos a 8 kHz.

7.6.4 O custo

Cada bloco é uma requisição, e a placa atende cerca de 8 por segundo (capítulo 8). Uma convolução de 5000 amostras por um filtro de 67 coeficientes são 5 requisições; um FIR sobre 5 s de áudio a 44,1 kHz são 216, perto de meio minuto. Enquanto isso, a barra de status das janelas mostra o bloco em curso (“Bloco 3 de 5 na FPGA”).

Capítulo 8

Várias placas, vários alunos

O laboratório tem duas placas e uma turma. Este capítulo descreve o que acontece entre um cliente e as placas quando várias pessoas usam o sistema ao mesmo tempo: como o cliente acha as placas, como escolhe uma, o que a fila do servidor faz com o tempo de resposta e o que foi medido. O texto completo, com as mensagens de diagnóstico, está em `docs/GERENCIAMENTO-PLACAS.md`.

8.1 Descoberta

O cliente procura placas em duas etapas.

A lista local. O `morphe-up.sh` grava toda placa que prepara em `.morphe-estado/placas`, um endereço por linha, na raiz do repositório; a última preparada fica também em `.morphe-estado/placa`. O cliente lê esses arquivos primeiro. Como a instalação de turma é uma só (`/opt/morphe`), o que o `morphe-up.sh` registra é o que todos os alunos daquele computador enxergam.

A varredura. Com a lista vazia, o cliente varre a rede por TCP, enviando um PING a cada endereço das sub-redes prováveis — a da placa lembrada, a do próprio computador e as usadas historicamente no laboratório — com até 64 conexões em paralelo e prazos curtos. A varredura **para na primeira placa que achar**. É o último recurso: o servidor não responde a *broadcast*, então uma placa numa sub-rede nunca vista continua invisível.

A lista é texto puro. Num computador que não é a estação, basta escrevê-la uma vez para o cliente passar a conhecer as duas placas:

```
printf '172.16.230.24\n172.16.230.52\n' > .morphe-estado/placas
```

Não se deve usar o `morphe-up.sh` só para registrar uma placa: mesmo sem reprogramar a FPGA, ele reinicia o servidor e interrompe quem estiver no meio de uma operação.

8.2 Escolha: a placa que responder mais rápido

Com mais de uma placa na lista, o cliente envia um PING a todas ao mesmo tempo e fica com a primeira que responder (Figura 8.1). Placas que respondem com `fpga_preparada=0` são ignoradas.

O tempo de resposta do PING mede ocupação por causa da estrutura do servidor: ele atende uma conexão de cada vez, então uma placa no meio de uma convolução só responde ao PING depois de terminá-la. Placa livre responde em milissegundos; placa ocupada, em centenas.

Duas placas livres empatam: a diferença entre elas é de microssegundos de rede, e a vencedora muda de uma vez para a outra. Não é defeito. É também por isso que dois alunos que cliquem




Figura 8.1: Escolha da placa: o cliente sonda todas em paralelo e fica com a que responder primeiro. Uma placa ocupada só responde ao fim da operação em curso.

no mesmo instante ainda podem cair na mesma placa; a regra resolve o caso comum, de uma placa ocupada e outra livre.

8.3 A fila e o tempo de resposta

Como o servidor atende uma conexão por vez, dois alunos na mesma placa **não recebem erro: esperam**. A segunda requisição fica na fila do sistema operacional até a primeira terminar, e os tempos se somam. Com k clientes disputando a mesma placa, cada um vê cerca de k vezes o tempo de placa livre.

A fila do `listen(4)` guarda cinco conexões, e a sexta é a que está sendo atendida. O que passa disso não é recusado: no Linux, o sistema descarta o pedido de conexão em silêncio e o cliente o repete cerca de um segundo depois. O sintoma do excesso é, portanto, uma cauda de latência, não um erro.

8.4 O que foi medido

As medições de 22/09/2026 usaram o `Python/ferramentas/testa_concorrencia.py`, que dispara requisições simultâneas e **confere cada resposta**: uma convolução com impulso tem de devolver a própria entrada, e a FFT de um impulso tem de dar espectro plano. Não bastava cronometrar; era preciso saber se alguma resposta chegava trocada.

Tabela 8.1: Vários clientes simultâneos, operações de 1024 amostras, metade convoluções (≈ 215 ms) e metade FFTs (≈ 21 ms). Placa livre: mediana de 120 ms (22/09/2026).

Cenário	Respostas certas	Mediana	p95	Pior
4 clientes, uma placa	32/32	471 ms ($3,9\times$)	—	—
6 clientes, uma placa	24/24	604 ms ($5,1\times$)	—	1,29 s
8 clientes, uma placa	64/64	517 ms	1,29 s	6,39 s
10 clientes, uma placa	80/80	519 ms	4,56 s	7,07 s
3 clientes em cada uma de duas máquinas, duas placas	90/90	—	—	—

Três conclusões:

- **Nenhuma resposta foi perdida nem trocada**, em nenhum cenário. As 90 requisições do teste com duas máquinas e duas placas foram conferidas uma a uma.
- **Uma placa atende cerca de 8 requisições por segundo** com essa mistura de operações, e esse número não muda de 2 para 10 clientes: é o tempo médio de uma operação

(120 ms) invertido. A partir de 8 clientes a placa está saturada, e cliente a mais só acrescenta espera. Duas placas dão cerca de 16 requisições por segundo para a turma inteira.

- O excesso aparece como cauda: de 8 para 10 clientes a mediana não se move e o p95 triplica.

Dois clientes gráficos, um em cada máquina, escolheram placas diferentes.

A captura do ADC ocupa a placa. Uma captura contínua mantém a conexão aberta enquanto dura, e durante esse tempo a placa não atende mais ninguém: outro aluno na mesma placa espera, e a escolha automática não a escolhe (o PING dela não responde). Numa aula com o ADC, é melhor reservar uma placa para a aquisição.

8.5 O que não existe

Estas são as limitações conhecidas da infraestrutura. Nenhuma impede o uso em turma com supervisão; todas impedem o uso sem supervisão com mais alunos do que placas.

1. **Alocação.** Nada impede duas pessoas de usarem a mesma placa achando que cada uma tem a sua. O resultado sai certo, porque cada requisição é completa, mas o tempo dobra e ninguém sabe por quê. Uma reserva com prazo, renovada pelo cliente, resolveria, e exige estado no servidor.
2. **Concorrência no servidor.** Um processo por conexão, ou uma fila explícita que respondesse “ocupada, você é o segundo”, diria ao cliente o que está acontecendo. Hoje ele não distingue “placa ocupada” de “placa fora do ar”: nos dois casos a sonda simplesmente demora.
3. **Descoberta sem varredura.** Um servidor que respondesse a *broadcast* UDP seria achado em qualquer sub-rede.
4. **Estado compartilhado entre computadores.** O `.morphe-estado` é de cada instalação.

8.6 Sintoma, causa e o que fazer

Tabela 8.2: Sintomas ligados a várias placas e vários clientes.

Sintoma	Causa	O que fazer
A escolha automática alterna entre as placas	duas placas livres empatam	nada; é o esperado
Tudo ficou duas vezes mais lento	outra pessoa está na mesma placa	é a fila; reconectar para ir à outra
“A placa não respondeu”, mas ela está no ar	placa ocupada (uma captura contínua, por exemplo)	esperar ou usar a outra
Operação recusada com “FPGA não preparada”	a placa foi ligada e ninguém programou o bitstream	<code>./morphe-up.sh</code> na estação
Um computador só enxerga uma placa	a lista dele está vazia e a varredura para na primeira	escrever <code>.morphe-estado/placas</code>
“o <i>tether</i> de DE-SoC [1-x] per-tence à conta ...”	outra conta preparou aquela placa	usá-la como está ou pedir àquela conta um <code>--down</code>

Capítulo 9

Preparação e operação do laboratório

Este capítulo é para quem prepara a aula: o professor, o monitor, ou o aluno que chegou primeiro. Descreve a rotina diária, o que o `morphe-up.sh` faz, a instalação para a turma, o Quartus nos computadores e como pôr uma placa nova em serviço. Os detalhes, com o histórico de cada decisão, estão em `PREPARACAO.md` e `docs/NOVA-PLACA.md`.

9.1 A rotina

Com as placas ligadas à rede e aos cabos USB-Blaster da estação, e a instalação de turma feita (seção 9.4), a aula começa com um comando na estação, uma vez por placa:

```
cd /opt/morphe && ./morphe-up.sh --cable 'DE-SoC [1-2]' --board 172.16.230.24
```

e cada aluno, em qualquer computador, abre o aplicativo:

```
cd /opt/morphe/Python && python3 morphe_app.py
```

Com uma placa só, o `./morphe-up.sh` sem argumentos basta: ele acha o cabo e a placa sozinho. Com duas, o `--cable` diz qual cabo e o `--board` qual placa; na estação do laboratório, o cabo `DE-SoC [1-2]` é o da placa `172.16.230.24` e o `DE-SoC [1-3]` o da `172.16.230.52`. Depois de preparada, a placa fica pronta até ser desligada ou até a estação ser desligada (seção 9.3).

Antes dessa rotina, preparar a plataforma levava 9 passos, dois deles com SSH na placa e cinco pontos de conhecimento que só o autor tinha; a contagem está em `docs/LINHA-DE-BASE-PASSOS.md`. Hoje são 3, e um deles é a própria operação.

9.2 O que o `morphe-up.sh` faz

A Figura 9.1 mostra os passos, na ordem em que o script os executa e imprime. Ele para no primeiro problema, com uma mensagem que diz o que fazer. Alguns passos merecem explicação.

Achar o Quartus. O script procura no `PATH`, em `$QUARTUS_ROOTDIR` e nas instalações usuais, e prefere a versão **20.1**, a que compilou o bitstream. Outra versão só é usada, com aviso, se não houver a 20.1 em lugar nenhum. Ele também **recusa rodar como root**: em 23/09/2026 um `sudo ./morphe-up.sh` achou o Quartus 22.1 da conta `root`, deixou o *tether* como processo do `root`, que nenhuma outra conta consegue encerrar, e pediu a senha da placa três vezes.

Descobrir o cabo. O nome do cabo JTAG (`DE-SoC [1-1]`, `[1-2]`, ...) depende da porta USB. O script o lê do `jtagconfig`, em vez de supor.




Figura 9.1: O que o `morphe-up.sh` faz, em ordem.

Programar e manter o *tether*. Ver a seção 9.3.

Servidor sempre depois da FPGA. O servidor é (re)iniciado depois de a FPGA ser programada, nunca antes, e o script grava a marca `/var/run/morphe-fpga-preparada` na placa (seção 4.3). O servidor é reenviado e recompilado se algum dos seus seis arquivos mudou.

Verificar. O `Quartus/morphe_ping.py` faz quatro testes contra a placa: conexão, PING, uma convolução de impulso (que tem de devolver a própria entrada) e uma FFT de impulso (que tem de dar espectro plano). O script só devolve o controle com os quatro passando, e traduz as falhas: falhar os dois primeiros é rede; passar os dois primeiros e falhar os dois últimos é FPGA ou `hps_0.h`.

Registrar. A placa vai para `.morphe-estado/placas`, que é o que os clientes leem (capítulo 8).

Tabela 9.1: As opções do `morphe-up.sh`.

Opção	O que faz
(nenhuma)	prepara a placa lembrada, ou a que achar na rede
<code>--board ip</code>	prepara esta placa, e passa a lembrá-la
<code>--cable nome</code>	usa este cabo JTAG, quando há mais de um
<code>--deploy</code>	reenvia e recompila o servidor mesmo sem mudança
<code>--skip-fpga</code>	só o servidor, sem reprogramar a FPGA
<code>--setup-ssh</code>	uma vez por placa e por conta: instala a chave SSH (seção 9.5)
<code>--status</code>	mostra, placa a placa, o que está no ar e se o <i>tether</i> está vivo
<code>--down</code>	encerra os <i>tethers</i> de todas as placas
<code>--down --stop-server</code>	e também para o servidor das placas

9.3 O *tether* da licença

O núcleo de FFT é um IP da Intel que a edição gratuita do Quartus só permite usar em modo de avaliação. O bitstream gerado assim (`soc_system_time_limited.sof`) funciona **enquanto o programador JTAG continuar conectado** à placa. Esse processo conectado é o *tether*. Quando ele termina, começa uma contagem de cerca de uma hora, e depois dela **o bitstream inteiro para** — não só a FFT: a convolução passa a esgotar o tempo (medido em 17/09/2026).

O programador do Quartus (`quartus_pgm`), depois de gravar, fica esperando uma tecla no terminal. O `morphe-up.sh` o deixa rodando em segundo plano, numa sessão própria, com uma entrada que nunca fecha, e guarda o identificador do grupo de processos para o `--down`. Há um *tether* por cabo JTAG, em `.morphe-estado/tethers/`, então preparar uma placa não derruba a outra.

Três fatos práticos:

- **o *tether* pertence a uma conta.** Se outra conta tentar reprogramar aquele cabo, o script para e diz de quem ele é;
- **sobrevive ao *logout*** se a estação tiver o *linger* ligado para a conta (`sudo loginctl enable-linger coordenador`, uma vez), mas **não sobrevive a desligar a estação**: depois de cada boot, alguém roda o `morphe-up.sh`;
- para saber se está vivo, de qualquer conta: `pgrep -af quartus_pgm`. Se não imprimir nada, qualquer resultado errado a partir daí é consequência disso.

9.4 A instalação de turma

A estação tem duas contas: `coordenador`, com `sudo`, e `alunopds`, sem. A pasta pessoal do coordenador não é legível pelo aluno, então a plataforma mora fora dela, em `/opt/morphe`, como um clone do repositório pertencente ao coordenador e ao grupo dos alunos. O Quartus mora em `/opt/intelFPGA_lite/20.1`, legível por todos.

Instalar, uma vez. Na conta do coordenador, copia-se o clone para `/opt/morphe`, sem o ambiente virtual do Python e sem as pastas de compilação do Quartus, e ajustam-se dono e permissões (os comandos estão em `PREPARACAO.md`). O ambiente virtual sai de propósito: o `python3` do sistema já tem NumPy, Matplotlib e SciPy, e o aluno não pode instalar nada.

Atualizar. Como `/opt/morphe` é um clone, atualizar é um `git pull` na conta do coordenador, sem `sudo`. Antes, confira o ramo com `git -C /opt/morphe branch -vv`: em 17/09/2026 um `pull` dizia “*Already up to date*” num ramo errado, e duas preparações rodaram com código antigo. Depois de um `pull` que mude o servidor ou o bitstream, rode o `morphe-up.sh` de novo.

Qualquer conta prepara a placa. Com o Quartus em `/opt` e a regra do USB-Blaster liberando o cabo para todos, o aluno também roda o `morphe-up.sh`. O preço: o `morphe-up.sh` de uma pessoa reprograma a FPGA e interrompe quem estiver usando aquela placa. A regra de bolso é rodá-lo para **começar a aula ou consertar uma placa parada**, não durante.

As duas contas no mesmo estado. O `.morphe-estado` é compartilhado; o script deixa as pastas com permissão 777 e os arquivos com 666 (o `/opt/morphe` inteiro é fechado para quem não é da turma), para que o que uma conta grava a outra possa reescrever.

Rodar sempre de `/opt/morphe`. O cliente lê a placa em `<raiz>/morphe-estado`, e quem escreve ali é o `morphe-up.sh`. Se os dois rodarem de pastas diferentes — o script de um clone na pasta pessoal, o aplicativo de `/opt/morphe` —, o aluno abre o aplicativo e não acha placa nenhuma. O sintoma parece de rede, e não é.

9.5 As chaves SSH

Sem chave, um `morphe-up.sh` pede a senha da placa três vezes. Uma vez por placa e por conta:

```
./morphe-up.sh --setup-ssh --board <ip da placa>
```

A chave criada é **RSA**, e as conexões habilitam o algoritmo `ssh-rsa`. As duas coisas são necessárias juntas: as placas rodam o OpenSSH 6.0, anterior às chaves `ed25519` (uma chave `ed25519` é gravada na placa e ignorada sem erro), e o OpenSSH 8.9 da estação desabilita por padrão o `ssh-rsa`, que é o único tipo que o servidor antigo assina.

9.6 O servidor no boot da placa

Uma vez por placa, instala-se o início automático do servidor (`C/autostart/`, capítulo 4). Com ele, a placa aparece na rede assim que liga — recusando operações até ser preparada — e o cliente não precisa de ninguém que saiba o endereço dela.

9.7 O Quartus em todos os computadores

Para que o aluno possa compilar um projeto próprio e programar a FPGA pelo cabo ligado ao computador em que está, cada computador precisa do Quartus **20.1**, da regra do USB-Blaster e do PATH. O `instala-quartus.sh`, rodado com `sudo` numa conta que o tenha, faz tudo isso, na ordem:

1. procura Quartus já instalados; uma 20.1 com Cyclone V fora das pastas pessoais é usada como está, uma dentro de uma pasta pessoal é copiada para `/opt`, e só sem nenhuma das duas a cópia vem da estação (ou de um disco externo, com `--origem`);
2. confere a versão e o suporte ao Cyclone V;
3. libera a leitura para todas as contas;
4. instala a regra `udev` do USB-Blaster, para qualquer conta enxergar o cabo;
5. cria a `libudev.so.0`, que o `jtagd` procura;
6. põe a 20.1 na frente do PATH, para todas as contas, em `/etc/profile.d/quartus.sh`;
7. cria o atalho “Quartus Prime Lite 20.1” no menu;
8. testa, da conta do aluno, a versão e o cabo.

A versão é sempre a mesma em todo o laboratório porque o Quartus é copiado da estação, e não baixado. O script pode ser rodado de novo sem estragar nada, e `--verificar` só confere. Em 23/09/2026 ele foi rodado em todos os computadores do laboratório.

Cuidado: gravar um projeto próprio numa placa que está servindo o Morphe substitui o bitstream da plataforma para todos os que a usam. Depois, `./morphe-up.sh` na estação a restaura.

9.8 O aplicativo nos outros computadores

O aplicativo não depende de nada da estação: basta uma cópia do repositório e o `python3` do sistema com NumPy e Matplotlib. Em cada computador, numa conta com `sudo`:

1. clonar o repositório em `/opt/morphe` e dar a leitura ao grupo dos alunos, como na estação;
2. escrever `/opt/morphe/.morphe-estado/placas` com os endereços das placas, um por linha, para o aplicativo não depender da varredura;
3. abrir o aplicativo da conta do aluno e conferir que ele acha as placas.

Não é preciso rodar o `morphe-up.sh` nesses computadores: as placas são preparadas pela estação, e os outros computadores só usam.

A armadilha do `pip --user`. Duas vezes o aplicativo quebrou numa conta por um NumPy ou Matplotlib instalado com `pip install --user`, incompatível com o outro pacote do sistema. Se o aplicativo não abrir com um erro de importação, remova **os dois juntos** — `python3 -m pip uninstall -y matplotlib numpy` — e confira que voltaram a vir de `/usr/lib/python3/dist-packages`. Remover só um deles deixa o outro incompatível e mantém o erro.

9.9 A placa na rede certa

As placas pegam endereço por DHCP, da rede do laboratório: hoje, a faixa `172.16.230.x`. Se o cabo de rede de uma placa for ligado num ponto de outra rede — outro switch, uma tomada de outra sala, um roteador pequeno na bancada —, ela recebe o endereço *daquela* rede e some para a estação e para os alunos. Foi o que aconteceu em 28/09/2026: a placa 2 subiu com `192.168.0.108`.

O `morphe-up.sh` mostra esse caso sem ambiguidade: a FPGA é programada (“*Configuration succeeded*”, porque o JTAG não depende da rede) e em seguida ele para com “não há caminho de rede até” a placa. O *tether* fica vivo, então não há pressa. Para resolver:

1. **Ver o endereço que a placa pegou**, pelo console serial (`screen /dev/ttyUSB0 115200`, conta `root`): `ip addr show eth0`. Se não for `172.16.x.x`, é a rede errada. Quem entregou o endereço aparece em `grep -h dhcp-server-identifier /var/lib/dhcp/dhclient*.leases`.
2. **Trocar o cabo de lugar**: ligá-lo no mesmo switch ou ponto de rede da outra placa, que está funcionando.
3. **Pedir um endereço novo, sem reiniciar a placa**, no console serial: `ifdown eth0` e depois `ifup eth0`. Conferir de novo com `ip addr show eth0`.
4. **Terminar a preparação sem reprogramar a FPGA**, na estação: `./morphe-up.sh --skip-fpga --board <ip>`. O `--skip-fpga` preserva o *tether*, que já está contando desde a programação.

Se o endereço novo for diferente do anterior dentro da rede certa (o DHCP pode trocá-lo), o `morphe-up.sh` com o `--board` novo o registra, e os clientes o encontram na próxima vez que abrirem. Um endereço que não muda exige pedir à TI uma reserva de DHCP para o MAC de cada placa (`02:00:00:6d:70:01` e `:02`).

9.10 Uma placa nova

Todas as DE1-SoC saem de fábrica com o **mesmo endereço MAC** (12:34:56:78:90:12) e os mesmos endereços IP fixos auxiliares. Duas placas na mesma rede disputam o endereço, e o sintoma — conexões intermitentes — parece defeito de placa. Por isso incorporar uma placa não é só ligá-la. Os passos, detalhados em `docs/NOVA-PLACA.md`:

1. **clonar o cartão SD** de uma placa que funciona, cuidando do tamanho: a imagem tem o tamanho do cartão de origem, e um cartão nominalmente igual pode ser menor;
2. **trocar o MAC no U-Boot**, pelo console serial (`setenv ethaddr 02:00:00:6d:70:NN` e `saveenv`, com *NN* o número da placa), e dar à placa um nome próprio;
3. **limpar o que o clone trouxe**: as concessões de DHCP da placa de origem e os endereços fixos de fábrica; configurar a rede como `auto eth0`;
4. instalar a chave SSH de cada conta e o início automático do servidor;
5. preparar com o `morphe-up.sh`, com o cabo e o endereço dela.

9.11 Sintoma, causa e o que fazer

Tabela 9.2: Sintomas da operação do laboratório.

Sintoma	Causa provável	O que fazer
Operações dão tempo esgotado, ou a FFT volta errada, depois de funcionar	o <i>tether</i> caiu há mais de uma hora	<code>pgrep -af quartus_pgm;</code> <code>./morphe-up.sh</code>
“FPGA não preparada”	a placa foi ligada depois da última preparação	<code>./morphe-up.sh</code>
“o bitstream na FPGA não é o deste servidor” (ADC)	servidor novo com bitstream antigo	<code>./morphe-up.sh</code> com o bitstream que tem o ADC
O aplicativo abre e não acha placa	o <code>morphe-up.sh</code> rodou de outra pasta, ou a lista está vazia	rodar de <code>/opt/morphe</code> ; escrever a lista
Permission denied <code>.morphe-estado</code>	no arquivo antigo gravado por outra conta	corrigir dono e permissões uma vez (<code>PREPARACAO.md</code>); nunca <code>sudo</code>
A senha da placa é pedida várias vezes	falta a chave desta conta	<code>--setup-ssh</code>
<code>qsys-generate: not found</code> ou Quartus fora do PATH	terminal em <code>ksh</code> , que não lê o <code>.bashrc</code>	digitar <code>bash</code> antes
O aplicativo não abre, com erro de importação	pacote instalado com <code>pip --user</code>	remover NumPy e Matplotlib juntos
“não há caminho de rede até” a placa, logo depois de programar a FPGA	o cabo de rede da placa está em outra rede (endereço fora de 172.16.x.x)	seção 9.9
A placa some da rede depois de ligada	cartão com servidor anterior a 21/09/2026 no início automático	atualizar o servidor da placa

Capítulo 10

Desenvolvimento e verificação

Este capítulo é para quem vai mudar o sistema: acrescentar uma operação, alterar um acelerador ou recompilar o hardware. Ele descreve o processo que foi usado para o IIR e para o ADC, os testes que existem e as regras que evitam os erros que já aconteceram.

10.1 Três regras antes de começar

O bitstream, o `hps_0.h` e o servidor são um conjunto. Misturar um bitstream de uma versão com um `hps_0.h` de outra **não produz erro**: o servidor escreve em endereços válidos, porém errados, e devolve zeros ou lixo. Foi essa a causa de dias de investigação equivocada durante a expansão para 1024 pontos. O comando `python3 Quartus/gen_hps_header.py --check` confere, sem Quartus, se o `hps_0.h` corresponde ao `soc_system.sopcinfo` ao lado; é a primeira coisa a rodar diante de um resultado inexplicável.

O `hps_0.h` é gerado, nunca editado. Um cabeçalho escrito à mão descreve um hardware que não existe. Ele sai do `.sopcinfo`, que sai do Platform Designer. Até para um teste rápido, gere.

O repositório manda, não a placa. Quando o que está numa placa diverge do repositório, o certo é descobrir por quê e levar a correção ao repositório — nunca copiar da placa para o repositório o que não se sabe de onde veio. Em 15/09/2026, na primeira compilação feita inteiramente a partir do repositório, a IFFT travou: o `fft_wrapper.v` versionado não era o que tinha gerado o bitstream em uso, porque uma correção do autor existia só numa cópia na estação. Até ali o repositório reproduzia o bitstream, mas não a compilação. O `PROVENIENCIA.sha256` (seção 10.6) existe para que isso não se repita.

10.2 Recompilar o bitstream

O projeto do Quartus está em `Quartus/`: o sistema do Platform Designer (`soc_system.qsys`), o topo (`ghrd_top.v`), os aceleradores e as restrições (`soc_system.qsf`, `soc_system_timing.sdc`). A compilação é feita na estação, no clone de desenvolvimento da conta do coordenador — onde ficam as pastas de trabalho do Quartus — e não em `/opt/morphe`. Os guias passo a passo são `docs/COMPILAR-IIR.md` e `docs/COMPILAR-ADC.md`; o roteiro geral é este:

1. **Simular primeiro.** Se o acelerador tem testbench, ele tem de passar antes de gastar meia hora de compilação (seção 10.3).
2. **Gerar o sistema.** Depois de mudar o `.qsys`:

```
qsys-generate soc_system.qsys --synthesis=VERILOG --family="Cyclone  
V--part=5CSEMA5F31C6
```

3. **Regenerar os endereços:** `python3 gen_hps_header.py`. Conferir que os símbolos novos apareceram no `C/hps_0.h`; se algum faltar, o Platform Designer não gerou o módulo.
4. **Compilar** (cerca de 30 minutos): `quartus_sh --flow compile soc_system.qpf`.
5. **Conferir recursos e tempo.** Em `output_files/` ficam o resumo de ocupação, `soc_system.fit.summary`, e a análise de tempo, `soc_system.sta.rpt`, em que a frequência máxima que vale é a do modelo “*Slow 1100mV 85C*”. Ela precisa ficar acima de 50 MHz. O `relatorio_timing.tcl` lista os caminhos críticos quando não fica.
6. **Programar e testar o que já funcionava**, antes do que é novo: `./morphe-up.sh` (que recompila o servidor, porque o `hps_0.h` mudou) e os testes da seção 10.4.
7. **Registrar.** Regerar a proveniência, versionar o bitstream, o `.sopcinfo` e o `hps_0.h` gerados, e anotar os números no `docs/DIARIO.md`.

Armadilhas conhecidas.

- Os `iir_*.v` **não estão listados** no `.qsf`: o Quartus os acha por estarem na pasta do projeto. Movê-los quebra a compilação.
- Depois de um `qsys-generate`, o bitstream *tem* de ser recompilado e reprogramado: o `sysid` muda, e o servidor passa a recusar o ADC com o bitstream antigo (seção 4.3). É o comportamento desejado.
- No clone de desenvolvimento da estação, nunca use `git reset --hard`: há arquivos de trabalho do Quartus rastreados por engano.
- Alguns terminais da estação abrem em `ksh`, que não lê o `.bashrc`: se um comando do Quartus der `not found`, digite `bash` antes.

Quando o tempo não fecha. Foi o que aconteceu na primeira compilação do IIR (49,11 MHz, 14/09/2026). O `relatorio_timing.tcl` mostrou que os quinze piores caminhos eram o mesmo: num único ciclo, o multiplexador que escolhe os operandos da seção corrente entre as 16, as cinco multiplicações de 32 bits, a soma de 72 bits, o arredondamento, a saturação e a escrita de volta — 19,7 ns de lógica em 20 ns. A correção foi um estado `S_SEL` no `iir_cascade.v`, que copia os operandos para registradores antes do cálculo; o registrador no meio da lógica é o que encurta o caminho (um simples estado de espera não mudaria nada, porque o analisador mede de registrador a registrador). A latência subiu de 24 para 35 ciclos por amostra, o resultado não mudou — o mesmo teste bit a bit provou isso — e a compilação seguinte fechou a 60,99 MHz.

10.3 Testbenches

Os aceleradores escritos no estágio têm testbench em Icarus Verilog, que roda no Linux e no Windows sem Quartus.

`Quartus/roda_tb_iir.sh` simula uma seção (`tb_iir_sos.v`) e a cascata (`tb_iir_cascade.v`) contra vetores gerados pelo Python/`ferramentas/gera_vetores_iir.py`, a partir do modelo em ponto fixo do `iir_design.py`. O critério é igualdade **bit a bit** em todas as amostras.

`Quartus/roda_tb_adc.sh` simula o `adc_captura.v` contra um modelo do LTC2308 que confere os tempos da folha de dados: captura única a várias taxas, divisor abaixo do mínimo, memória cheia, captura contínua com a memória dando a volta, parada no meio de um quadro, e captura única depois da contínua. Confere o período exato, o canal, a ordem dos bits e, na contínua, que o contador corresponde à última amostra gravada.

Os dois terminam imprimindo TUDO OK ou a primeira divergência.

10.4 Testes contra a placa

As ferramentas de teste ficam em `Python/ferramentas/` e rodam de dentro de `Python/`, com o endereço da placa como argumento. Todas conferem resultados contra uma referência, e não só a ausência de erro.

Tabela 10.1: Os testes contra a placa.

Ferramenta	O que confere
<code>Quartus/morphe_ping.py</code>	os quatro testes do <code>morphe-up.sh</code> : conexão, protocolo, convolução de impulso, FFT de impulso
<code>testa_bit_inverse.py</code>	o bit <code>inverse</code> do núcleo da FFT e a convenção $1/N$
<code>testa_ifft_roundtrip.py</code>	$\text{sin} \rightarrow \text{FFT} \rightarrow \text{IFFT} \rightarrow \text{sin}$, contra o NumPy
<code>testa_iir_hw.py</code>	o IIR da placa contra o modelo em ponto fixo, bit a bit, em vários filtros
<code>testa_blocos.py</code>	o processamento em blocos (sem placa, contra o NumPy; com <code>--placa</code> , contra a placa) e a leitura de arquivos
<code>testa_concorrencia.py</code>	vários clientes ao mesmo tempo, conferindo cada resposta (capítulo 8)
<code>testa_adc.py</code>	o ADC em degraus: <code>basico</code> (sem nada ligado), <code>tensao</code> (com multímetro), <code>senoide</code> (com gerador), <code>continuo</code> (captura longa, conferindo as emendas) e <code>canais</code>
<code>compara_professor_fpga.py</code>	o <code>dsp_iir_filter.m</code> do Prof. Sanca contra a placa, separando o custo do ponto fixo do que é limitação do MATLAB

Depois de qualquer bitstream novo, a sequência mínima é o `morphe-up.sh` (quatro testes), `testa_ifft_roundtrip.py`, `testa_iir_hw.py` e `testa_blocos.py --placa`. Foi o que se rodou em 24/09/2026 com o bitstream do ADC, antes de testar o ADC: nada do que já existia mudou.

O tempo como diagnóstico. Cada operação tem um tempo típico na placa (cerca de 170 ms na FPGA para uma convolução de 1024 por 1024, cerca de 21 ms de ponta a ponta para a FFT), e o servidor o registra em cada operação. Um tempo muito menor é sinal de defeito, não de sorte: um bitstream mal compilado já foi visto terminar a convolução em 3,3 ms sem ter calculado nada.

Diagnóstico sem o servidor. Quando é preciso saber se o problema está no servidor ou no hardware, dá para escrever e ler as memórias e os registradores direto pelo `/dev/mem`, na placa. O procedimento está no item 15 do `docs/RESSALVAS.md`.

10.5 Sem placa: o servidor em simulação

O servidor em C pode ser exercitado sem placa. Em 24/09/2026, para o ADC, o `morphe_server.c` foi compilado num Linux x86 com o `/dev/mem` trocado por memória comum e uma `thread` fazendo o papel do `adc_captura.v`. Isso permitiu testar a captura contínua (sequências idênticas amostra por amostra em 100 mil amostras, perda forçada, cliente que fecha a conexão no meio) antes da primeira compilação do bitstream. O mesmo arranjo serve para qualquer operação nova: o servidor não sabe que a memória não é a da FPGA.

10.6 A proveniência

O `PROVENIENCIA.sha256`, na raiz, lista o *hash* SHA-256 do conjunto inseparável: os fontes de hardware que viram bitstream (`conv1d.v`, `fft_wrapper.v`, `iir_*.v`, `adc_captura.v`, `ghrd_top.v`, `soc_system.qsys`), o `.sopcinfo`, o bitstream, o `hps_0.h`, o `morphe_config.h` e o servidor. O cabeçalho diz em que máquina, de que *commit* e com que validação ele foi gerado.

Conferir um clone é um comando, da raiz:

```
sha256sum -c PROVENIENCIA.sha256
```

Regerar é tarefa de quem compilou e validou, na máquina onde o fez, logo depois da validação:

```
./gera_proveniencia.sh "morphe_ping 4/4; IFFT 0 falhas; Fmax 61,56 MHz"
```

O script se recusa a rodar sem a frase de validação: *proveniência sem validação não é proveniência*. Ele existe porque o arquivo, editado à mão, ficou desatualizado duas vezes.

10.7 Fluxo de trabalho com o git

- O repositório de trabalho é o *fork* `nicassiosantos/morphe` no GitHub. O ramo principal do estágio é `estagio/v1.1-1024pontos`; cada mudança de hardware nasce num ramo próprio (`estagio/v1.3-iir-hw`, `estagio/v1.7-adc`) e só é mesclada depois de validada na placa. Enquanto isso, o bitstream do ramo principal continua valendo.
- Na estação, o clone de desenvolvimento e o `/opt/morphe` só recebem mudanças por `git pull`. O que for gerado na estação (`bitstream`, `.sopcinfo`, `hps_0.h`) é versionado de lá.
- Antes de um `pull` em `/opt/morphe`, confira o ramo (`git branch -vv`).
- Toda validação vai para o `docs/DIARIO.md`, com o número medido e onde foi medido; trabalho escrito e não validado fica marcado como tal.

10.8 Acrescentar um acelerador

Juntando tudo, o caminho de um acelerador novo, na ordem que evita retrabalho:

1. um modelo em Python, em ponto fixo, que defina o resultado esperado bit a bit — e o estudo de viabilidade numérica nele, antes de qualquer Verilog (foi assim com o IIR: o `estuda_iir_ponto_fixo.py` respondeu se o Q15.16 bastava antes de o RTL existir);
2. o RTL, obedecendo ao protocolo comum de `start` e `done` (seção 3.3), e o seu testbench contra o modelo;
3. memórias e registradores no Platform Designer, nos primeiros endereços livres, sem mover os existentes; a instância no `ghrd_top.v`;
4. a compilação (seção 10.2);
5. a operação no protocolo e no servidor (seção 5.6);
6. um teste contra a placa, em `Python/ferramentas/`;
7. a janela, por último.

Capítulo 11

Limitações e trabalho futuro

Este capítulo reúne o que o sistema não faz hoje, cada item com o motivo e, quando há, o caminho para resolvê-lo. Nada aqui impede o uso em aula; são os pontos de partida para quem continuar o trabalho.

11.1 Hardware

Tamanho fixo de 1024 amostras. Os aceleradores foram sintetizados para blocos de 1024. Sinais maiores são tratados no cliente, por blocos (seção 7.6), com o custo de uma requisição por bloco. Aumentar o bloco exige memórias maiores, um núcleo de FFT gerado de novo e, para a convolução, aceitar um tempo que cresce com o quadrado do tamanho: 1024 por 1024 já leva 170 ms.

A licença de avaliação da FFT. O bitstream só funciona com o *tether* vivo, e para uma hora depois de ele cair (seção 9.3). O `morphe-up.sh` torna isso invisível na rotina, mas a estação precisa ficar ligada durante a aula e o `morphe-up.sh` tem de rodar depois de cada boot dela. As saídas são uma licença do núcleo da Intel, ou uma FFT própria em Verilog, que tiraria a restrição e daria controle sobre a aritmética interna (hoje o teto de 92 dB é do núcleo).

A aritmética do conv1d. A convolução e o FIR truncam os produtos e deixam o acumulador dar a volta. Trocar por arredondamento e saturação reduziria o erro máximo de 521 para 25 LSB e eliminaria o estouro silencioso. A troca foi avaliada e deliberadamente não feita, para manter o comportamento descrito no TCC original (seção 3.3.2); é uma decisão a rever com o supervisor, não uma pendência técnica.

Restos do projeto original. O IP de FIR da Intel (`fir_ii`) e o seu adaptador continuam no projeto sem instância, e o registrador `fir_error` não é acionado por nada. Podem sair numa próxima compilação, junto com a conferência de que nada mudou.

11.2 Aquisição

O que falta validar. Na data deste manual o ADC foi validado na placa com tensões contínuas (0 V e 3,3 V, contra o valor nominal) e com a captura contínua a 200 kHz sem perda; **falta a validação com uma senoide do gerador de funções** (SINAD e ENOB medidos, e a continuidade das emendas entre blocos com um sinal que muda) e a comparação da leitura em 3,3 V com um multímetro. O roteiro está em `docs/COMPILAR-ADC.md`, passos 7c e 7d, e no `testa_adc.py`.

Não há filtro *anti-aliasing*. O sinal chega ao conversor sem filtro analógico. Um tom acima de $f_s/2$ aparece dobrado no espectro. Para medir, isso é uma limitação; para ensinar amostragem, é uma oportunidade.

Faixa de entrada. A entrada lê de 0 a 4,095 V e pode ser danificada abaixo de $-0,3$ V. Um sinal alternado precisa de deslocamento DC antes do conector. Um pequeno circuito de condicionamento (deslocamento, proteção e filtro) tornaria a entrada segura para uso direto pelos alunos.

Um canal por captura. A captura lê um canal, ou um par diferencial, por vez. Como o LTC2308 recebe a palavra de configuração a cada conversão, alternar dois canais é uma mudança pequena no `adc_captura.v` (e exige recompilar); abriria correlação cruzada e estimativa de atraso.

A placa fica ocupada durante a captura. A captura contínua mantém a conexão aberta, e o servidor não atende mais ninguém nesse tempo (capítulo 8). Limitar a duração, ou atender outras operações durante a captura, são decisões ainda em aberto.

11.3 Infraestrutura

Descritas no capítulo 8: **não há alocação de placas** (duas pessoas podem cair na mesma placa sem saber), **o servidor não atende em paralelo** nem diz ao cliente que está ocupado, **a descoberta depende de varredura** e **o estado de cada instalação não é compartilhado**. As quatro se resolvem juntas com um serviço que gerencie as placas, com reserva por prazo e resposta explícita de ocupação — o que o plano do estágio chamou de versão 1.4.

Instalação nos computadores. O Quartus tem um instalador (`instala-quartus.sh`); o aplicativo, não: a instalação nos outros computadores é o procedimento manual da seção 9.4 e seguintes. Um script, com um atalho no menu de aplicativos, seria o próximo passo natural.

11.4 Ideias que a plataforma já permite

Com o que existe hoje, sem mudar o hardware:

- aula de amostragem e *aliasing*, capturando um tom do gerador acima e abaixo de $f_s/2$;
- analisador de espectro, com capturas repetidas e a FFT da placa;
- medir o próprio conversor (SINAD, ENOB) e comparar com os 74 dB teóricos de 12 bits;
- multitaxa: capturar rápido e dizimar com o FIR da placa;
- os exercícios do Oppenheim que usam sequências dadas, agora que o aplicativo lê sinais de arquivo de qualquer tamanho;
- estudar o efeito da quantização dos coeficientes de um IIR de ordem alta em forma direta contra seções de segunda ordem, com o projetista e o comparador.

Apêndice A

Estrutura do repositório

A árvore abaixo mostra o que importa em cada pasta. A separação entre o que é produto (o que roda quando alguém usa o Morphe) e o que não é está também no `README.md` da raiz.

```
morphe/
├── README.md ..... ponto de entrada
├── morphe-up.sh ..... prepara a placa: FPGA, servidor, marca
├── instala-quartus.sh ..... Quartus 20.1 para todas as contas de um PC
├── deploy.sh, gera_proveniencia.sh, PROVENIENCIA.sha256
├── Python/ ..... o aplicativo
│   ├── morphe_app.py ..... janela principal
│   ├── *_window.py ..... uma janela por operação
│   ├── morphe_protocol.py ..... cliente TCP
│   ├── dsp_core.py, blocos.py ..... ponto fixo, referência, sinais longos
│   ├── fir_design.py, iir_design.py ..... projetistas de filtros
│   ├── aquisicao.py, sinal_arquivo.py ..... ADC e sinais de arquivo
│   └── ferramentas/ ..... testes contra a placa, figuras, vetores
├── C/ ..... o servidor da placa
│   ├── morphe_server.c, morphe_protocol.h, morphe_config.h
│   ├── hps_0.h ..... gerado do Platform Designer
│   └── autostart/
├── Quartus/ ..... o hardware
│   ├── ghrd_top.v ..... topo: instancia os aceleradores
│   ├── conv1d.v, fft_wrapper.v, iir_*.v ..... os aceleradores
│   ├── adc_captura.v ..... o controlador do ADC
│   ├── soc_system.qsys, soc_system.qsf
│   ├── tb_*.v, roda_tb_*.sh ..... testbenches (IIR e ADC)
│   ├── gen_hps_header.py ..... gera o hps_0.h
│   └── output_files/ ..... o bitstream
├── exemplos/ ..... pacotes .mrph e sinais de exemplo
├── docs/ ..... documentação técnica, diário e este manual
└── legado/ ..... do projeto original, fora do produto
```

Três regras sobre esta estrutura:

- os `iir_*.v` não saem de `Quartus/`: não estão listados no `soc_system.qsf`, e o Quartus os acha por estarem na pasta do projeto;
- o `C/hps_0.h` e o `Quartus/soc_system.sopcinfo` são gerados, e vão juntos com o bitstream que os gerou;

- as ferramentas rodam de dentro de Python/, porque o `ferramentas/_caminho.py` acrescenta a pasta de cima ao caminho de importação; por exemplo:
`python3 ferramentas/testa_iir_hw.py <ip>`.

Tabela A.1: A documentação técnica, em `docs/` e na raiz.

Arquivo	Assunto
<code>PREPARACAO.md</code>	preparar a placa, instalar para a turma, Quartus nos computadores
<code>docs/GERENCIAMENTO-PLACAS.md</code>	várias placas e vários clientes
<code>docs/PRECISAO-NUMERICA.md</code>	os formatos de ponto fixo e os erros medidos
<code>docs/ADC.md</code>	o conversor da placa e como a captura funciona
<code>docs/COMPILAR-IIR.md</code> , <code>docs/COMPILAR-ADC.md</code>	recompilar o bitstream, passo a passo
<code>docs/NOVA-PLACA.md</code>	pôr uma placa nova em serviço
<code>docs/RESSALVAS.md</code>	o que foi corrigido no projeto original, e por quê
<code>docs/LINHA-DE-BASE-PASSOS.md</code>	a medição de usabilidade antes das mudanças
<code>docs/DIARIO.md</code>	o diário do estágio: o que foi feito, medido e validado, dia a dia
<code>docs/manual/</code>	este manual

Apêndice B

Referência rápida

Os comandos do dia a dia. Os da estação rodam de `/opt/morphe`, na conta de quem vai preparar a aula; nunca com `sudo`.

Preparar as placas (estação)

```
cd /opt/morphe && ./morphe-up.sh --cable 'DE-SoC [1-2]' --board 172.16.230.24
./morphe-up.sh --cable 'DE-SoC [1-3]' --board 172.16.230.52
Ver o que está no ar, e se os tethers estão vivos:
./morphe-up.sh --status
pgrep -af quartus_pgm
```

Abrir o aplicativo (qualquer computador)

```
cd /opt/morphe/Python && python3 morphe_app.py
```

Uma vez por placa e por conta

```
./morphe-up.sh --setup-ssh --board <ip>
```

Atualizar a instalação de turma (coordenador)

```
git -C /opt/morphe branch -vv
```

```
cd /opt/morphe && git pull
```

e, se o servidor ou o bitstream mudaram, `./morphe-up.sh` de novo.

Conferir um clone

```
sha256sum -c PROVENIENCIA.sha256
```

```
python3 Quartus/gen_hps_header.py --check
```

Testar contra a placa (de dentro de Python/)

```
python3 ../Quartus/morphe_ping.py <ip>
python3 ferramentas/testa_ifftr_roundtrip.py <ip>
python3 ferramentas/testa_iir_hw.py <ip>
python3 ferramentas/testa_blocos.py --placa <ip>
python3 ferramentas/testa_adc.py <ip> basico
python3 ferramentas/testa_concorrencia.py --modo mesma --clientes 6
```

Encerrar

```
./morphe-up.sh --down
```

encerra os *tethers*; em uma hora as placas param. Com `--stop-server`, para também os servidores.

Quando algo dá errado

Sintoma	Primeiro passo
tempo esgotado, FFT errada	<code>pgrep -af quartus_pgm; ./morphe-up.sh</code>
“FPGA não preparada”	<code>./morphe-up.sh</code>
aplicativo não acha placa	rodar tudo de <code>/opt/morphe</code> ; conferir <code>.morphe-estado/placas</code>
resultado inexplicável	<code>gen_hps_header.py --check</code>
aplicativo não abre	remover NumPy e Matplotlib do <code>pip --user</code>

As tabelas completas estão nos capítulos 8 e 9.